

MAT-466: Definición de GLMs

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Definición 1 (Modelo lineal generalizado):

Suponga Y_1, \dots, Y_n variables aleatorias **independientes** cada una con densidad

$$f(y_i; \theta_i, \phi) = \exp[\phi\{y_i\theta_i - b(\theta_i)\} + c(y_i, \phi)], \quad (1)$$

donde

$$E(Y_i) = \mu_i = b'(\theta_i), \quad \text{var}(Y_i) = \phi^{-1}V(\mu_i),$$

con $V(\mu) = d\mu/d\theta$ la **función de varianza**¹ y $\phi^{-1} > 0$ es el parámetro de dispersión.

Los modelos lineales generalizados (GLM) son definidos por (1) y

$$g(\mu_i) = \eta_i, \quad \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta},$$

donde η_i corresponde al **predictor lineal**, $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$, ($p < n$) es el vector de **coeficientes de regresión** y $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ denota un vector de variables regresoras. Además, la función $g(\cdot)$ es monótona y diferenciable y se denomina **función de enlace**.

¹En adelante anotaremos simplemente, $V_i = V(\mu_i)$, para $i = 1, \dots, n$.

Definición 1 (Modelo lineal generalizado):

Suponga Y_1, \dots, Y_n variables aleatorias independientes cada una con densidad

$$f(y_i; \theta_i, \phi) = \exp[\phi\{y_i\theta_i - b(\theta_i)\} + c(y_i, \phi)], \quad (1)$$

donde

$$E(Y_i) = \mu_i = b'(\theta_i), \quad \text{var}(Y_i) = \phi^{-1}V(\mu_i),$$

con $V(\mu) = d\mu/d\theta$ la función de varianza¹ y $\phi^{-1} > 0$ es el parámetro de dispersión.

Los modelos lineales generalizados (GLM) son definidos por (1) y

$$g(\mu_i) = \eta_i, \quad \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta},$$

donde η_i corresponde al predictor lineal, $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$, ($p < n$) es el vector de coeficientes de regresión y $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ denota un vector de variables regresoras. Además, la función $g(\cdot)$ es monótona y diferenciable y se denomina función de enlace.

¹En adelante anotaremos simplemente, $V_i = V(\mu_i)$, para $i = 1, \dots, n$.

Ejemplo (distribución normal):

Considere $Y \sim N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$ y $\sigma^2 > 0$. De este modo

$$\begin{aligned} f(y; \mu, \sigma^2) &= (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2} \left(\frac{y - \mu}{\sigma} \right)^2 \right\} \\ &= \exp \left\{ \frac{1}{\sigma^2} \left(\mu y - \frac{\mu^2}{2} \right) - \frac{1}{2} \left(\log 2\pi\sigma^2 + \frac{y^2}{\sigma^2} \right) \right\}. \end{aligned}$$

Luego, $\theta = \mu$, $b(\theta) = \theta^2/2$, $\phi = 1/\sigma^2$ y

$$c(y, \phi) = \frac{1}{2} \log(\pi/2\pi) - \frac{\phi y^2}{2}.$$

Verificamos fácilmente que $V(\mu) = 1$.



Ejemplo (distribución Bernoulli):

Suponga $Y \sim \text{Ber}(\mu)$, $\mu \in (0, 1)$. Tenemos

$$\begin{aligned}f(y; \mu) &= \mu^y (1 - \mu)^{1-y} \\&= \exp\{y \log \mu + (1 - y) \log(1 - \mu)\} \\&= \exp\left\{y \log\left(\frac{\mu}{1 - \mu}\right) + \log(1 - \mu)\right\}.\end{aligned}$$

De ahí que

$$\theta = \log\left(\frac{\mu}{1 - \mu}\right) \quad \Rightarrow \quad \mu = \frac{e^\theta}{1 + e^\theta},$$

de donde obtenemos $b(\theta) = \log(1 + e^\theta)$ y $\phi = 1$. Es fácil verificar

$$\begin{aligned}b'(\theta) &= \frac{1}{1 + e^\theta} \frac{d}{d\theta}(1 + e^\theta) = \frac{e^\theta}{1 + e^\theta} = \mu \\b''(\theta) &= \frac{d}{d\theta}\left(\frac{e^\theta}{1 + e^\theta}\right) = \frac{e^\theta(1 + e^\theta) - e^{2\theta}}{(1 + e^\theta)^2} = \mu - \mu^2 = \mu(1 - \mu) = V(\mu).\end{aligned}$$



Ejemplo (distribución Poisson):

Sea $Y \sim \text{Poi}(\mu)$, $\mu > 0$, con densidad

$$f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!} = \exp(y \log \mu - \mu - \log y!),$$

sigue que $\theta = \log \mu$, $b(\theta) = e^\theta$, $\phi = 1$ y $c(y, \phi) = -\log y!$ Además,

$$b'(\theta) = e^\theta = \mu, \quad b''(\theta) = e^\theta = \mu = V(\mu).$$



Ejemplo (distribución Gama):

Considere $Y \sim \text{Gama}(\mu, \phi)$, cuya densidad es dada por

$$\begin{aligned} f(y; \mu, \phi) &= \frac{y^{-1}}{\Gamma(\phi)} \left(\frac{\phi y}{\mu} \right)^{\phi} \exp \left(- \frac{\phi y}{\mu} \right) \\ &= \exp \{ \phi(-y/\mu - \log \mu) - \log \Gamma(\phi) + \phi \log(\phi y) - \log y \}. \end{aligned}$$

De ahí que $\theta = -1/\mu$, $b(\theta) = -\log(-\theta)$, y

$$c(y; \phi) = (\phi - 1) \log y + \phi \log \phi - \log \Gamma(\phi).$$

Ahora,

$$b'(\theta) = -\frac{1}{\theta} = \mu, \quad b''(\theta) = \frac{1}{\theta}.$$

Por tanto, $V(\mu) = \mu^2$, y $\text{var}(Y) = \mu^2/\phi$.



Ejemplo (distribución normal inversa):

Sea $Y \sim \text{IG}(\mu, \phi)$, con densidad

$$\begin{aligned} f(y; \mu, \phi) &= \left(\frac{\phi}{2\pi y^3} \right)^{1/2} \exp \left\{ -\frac{\phi}{2y} \left(\frac{y - \mu}{\mu} \right)^2 \right\} \\ &= \exp \left\{ \phi \left(-\frac{y}{2\mu^2} + \frac{1}{\mu} \right) - \frac{1}{2} \left(\log(2\pi y^3 / \phi) + \frac{\phi}{y} \right) \right\} \end{aligned}$$

Haciendo $\theta = -1/(2\mu^2)$, $b(\theta) = -(-2\theta)^{1/2}$, y

$$c(y; \phi) = \frac{1}{2} \log \left(\frac{\phi}{2\pi y^3} \right) - \frac{\phi}{2y}.$$

Para $Y \sim \text{IG}(\mu, \phi)$ sigue que $V(\mu) = \mu^3$.



Definición 2 (enlace canónico):

Sea $\mu = \tau(\theta) = b'(\theta)$. La transformación inversa

$$\theta = \tau^{-1}(\mu),$$

es llamada **función de enlace**.

Ejemplos:

- ▶ **Normal:** $\theta = \mu$.
- ▶ **Bernoulli:** $\theta = \log\left(\frac{\mu}{1-\mu}\right) = \text{logit}(\mu)$.
- ▶ **Poisson:** $\theta = \log \mu$.
- ▶ **Gamma:** $\theta = 1/\mu$.
- ▶ **Normal inversa:** $\theta = 1/\mu^2$.



Modelo lineal generalizado

Suponga $Y \sim \text{Ber}(\mu)$, $\mu \in (0, 1)$. Considere la distribución logística con función de densidad

$$f(y) = \frac{e^y}{(1 + e^y)^2} \quad \Longleftrightarrow \quad F(y) = \frac{e^y}{1 + e^y},$$

de ahí que podemos escribir la función de [enlace logístico](#) como:

$$\theta = \text{logit}(\mu) = F^{-1}(\mu).$$

Lo anterior motiva las siguientes funciones de enlace:

- [Enlace probit](#): Considere la transformación:

$$\theta = \Phi^{-1}(\mu).$$

- [Enlace complemento log-log](#): Considere

$$f(y) = \exp(y - e^y), \quad F(y) = 1 - \exp(-e^y),$$

de ahí que

$$\theta = \log(-\log(1 - \mu)).$$



- **Enlace Box-Cox:** Este enlace es definido para variables aleatorias positivas

$$\theta = \frac{\mu^\lambda - 1}{\lambda}, \quad \lambda \neq 0,$$

note que, para $\lambda \rightarrow 0$ obtenemos $\theta = \log \mu$.

- **Enlace Aranda-Ordaz:** esta función de enlace se define por la transformación:

$$\theta = \log \left\{ \frac{(1 - \mu)^{-\alpha} - 1}{\alpha} \right\}, \quad \mu \in (0, 1).$$

Cuando $\alpha = 1$, tenemos $\theta = \text{logit}(\mu)$, mientras que $\alpha \rightarrow 0$, sigue que $\theta = \log(-\log(1 - \mu))$.



Modelo lineal generalizado

Suponga Y_1, \dots, Y_n variables aleatorias independientes cada una con distribución $FE(\theta_i, \phi)$. Entonces, la densidad conjunta adopta la forma:

$$f(\mathbf{y}; \boldsymbol{\theta}, \phi) = \exp \left[\phi \sum_{i=1}^n \{y_i \theta_i - b(\theta_i)\} + \sum_{i=1}^n c(y_i; \phi) \right].$$

De ahí que, la función de log-verosimilitud es dada por

$$\ell(\boldsymbol{\theta}) = \phi \sum_{i=1}^n \{y_i \theta_i - b(\theta_i)\} + \sum_{i=1}^n c(y_i; \phi).$$

Sea $\mu_i = g^{-1}(\eta_i)$, $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$, y considere $\ell(\boldsymbol{\mu}; \mathbf{y})$, $\ell(\mathbf{y}; \mathbf{y})$, las funciones de log-verosimilitud para el modelo de trabajo con $\mu_i = g^{-1}(\eta_i)$, $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ y el modelo saturado ($p = n$), respectivamente.



Modelo lineal generalizado

Recuerde que podemos escribir

$$D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \phi D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2\{\ell(\mathbf{y}; \mathbf{y}) - \ell(\hat{\boldsymbol{\mu}}; \mathbf{y})\}.$$

Suponga que $\hat{\theta}_i = \theta_i(\hat{\boldsymbol{\mu}}_i)$ y $\tilde{\theta}_i = \theta_i(\tilde{\boldsymbol{\mu}}_i)$ los MLE de $\boldsymbol{\theta}$ para el modelo con p parámetros ($p < n$) y el modelo saturado ($p = n$), respectivamente. De ahí que

$$\ell(\hat{\boldsymbol{\mu}}; \mathbf{y}) = \phi \sum_{i=1}^n \{y_i \hat{\theta}_i - b(\hat{\theta}_i)\} + \sum_{i=1}^n c(y_i; \phi)$$

$$\ell(\tilde{\boldsymbol{\mu}}; \mathbf{y}) = \phi \sum_{i=1}^n \{y_i \tilde{\theta}_i - b(\tilde{\theta}_i)\} + \sum_{i=1}^n c(y_i; \phi).$$

Ahora,

$$\begin{aligned} D^*(\mathbf{y}; \hat{\boldsymbol{\mu}}) &= 2\{\ell(\mathbf{y}; \mathbf{y}) - \ell(\hat{\boldsymbol{\mu}}; \mathbf{y})\} \\ &= 2\phi \sum_{i=1}^n [y_i(\tilde{\theta}_i - \hat{\theta}_i) + \{b(\hat{\theta}_i) - b(\tilde{\theta}_i)\}]. \end{aligned}$$



Modelo lineal generalizado

Finalmente, podemos escribir

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n d_i^2(y_i; \hat{\mu}_i),$$

con

$$d_i^2(y_i; \hat{\mu}_i) = 2\{y_i(\tilde{\theta}_i - \hat{\theta}_i) + (b(\hat{\theta}_i) - b(\tilde{\theta}_i))\},$$

es conocido como el **componente del desvío** (no escalado).

Ejemplo (modelo normal):

Tenemos $\theta_i = \mu_i$, luego $\tilde{\theta}_i = y_i$ y $\hat{\theta}_i = \hat{\mu}_i$. Luego, la función desvío asume la forma:

$$\begin{aligned} D(\mathbf{y}; \hat{\boldsymbol{\mu}}) &= 2 \sum_{i=1}^n \left\{ y_i(y_i - \hat{\mu}_i) + \frac{\hat{\mu}_i^2}{2} - \frac{y_i^2}{2} \right\} \\ &= \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 \quad (= RSS) \end{aligned}$$



Ejemplo (modelo Poisson):

En este caso $\theta_i = \log \mu_i$. De ahí que,

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right\}.$$

Para $y_i = 0$ tenemos

$$f(y_i; \mu_i) = \frac{e^{-\mu_i} \mu_i^0}{0!} = e^{-\mu_i},$$

en cuyo caso

$$d_i^2(y_i; \hat{\mu}_i) = 2\hat{\mu}_i.$$



Modelo lineal generalizado

Ejemplo (modelo Gama):

Tenemos $\theta_i = -1/\mu_i$. Así,

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = 2 \sum_{i=1}^n \left\{ -\log \left(\frac{y_i}{\hat{\mu}_i} \right) + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i} \right\}.$$

Ejemplo (modelo normal inversa):

Sabemos que $\theta_i = -1/(2\mu_i^2)$, por tanto

$$D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}.$$

