

MAT-466: Test de hipótesis en GLM

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Considere la hipótesis simple,

$$H_0 : \beta = \beta_0 \quad \text{versus} \quad H_1 : \beta \neq \beta_0,$$

con β_0 un vector conocido.¹

- **Test de razón de verosimilitudes (LRT):** Para el caso de hipótesis simples, el estadístico de razón de verosimilitudes es dado por:

$$LR = 2\{\ell(\hat{\beta}) - \ell(\beta_0)\} \xrightarrow{D} \chi^2(p),$$

para el caso de GLMs, el estadístico LRT adopta la forma:

$$LR = \phi\{D(\mathbf{y}; \mu_0) - D(\mathbf{y}; \hat{\mu})\},$$

donde $\mu_0 = g^{-1}(\eta_0)$, $\eta_0 = \mathbf{X}\beta_0$, y análogamente para $\hat{\mu} = g^{-1}(\hat{\eta})$, con $\hat{\eta} = \mathbf{X}\hat{\beta}$.

¹ asumiremos ϕ conocido.

- **Test de Wald:** El estadístico de Wald es definido como

$$W = (\hat{\beta} - \beta_0)^\top \{\text{Cov}(\hat{\beta})\}^{-1} (\hat{\beta} - \beta_0),$$

donde $\text{Cov}(\hat{\beta})$ corresponde a la matriz de covarianza de $\hat{\beta}$.²

Para GLMs, sabemos que

$$\text{Cov}(\hat{\beta}) = \mathcal{F}(\beta) \big|_{\beta=\hat{\beta}} = \phi(\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1},$$

donde $\widehat{\mathbf{W}} = \text{diag}(\hat{w}_1, \dots, \hat{w}_n)$ con $\hat{w}_i = \omega_i(\hat{\mu}_i)$. De este modo,

$$W = \phi(\hat{\beta} - \beta_0)^\top (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X}) (\hat{\beta} - \beta_0) \xrightarrow{D} \chi^2(p).$$

²que debe ser estimada bajo H_1 .

Observación:

Suponga $p = 1$, entonces

$$W = \frac{(\hat{\beta} - \beta_0)^2}{\text{var}(\hat{\beta})} \xrightarrow{D} \chi^2(1),$$

que es equivalente al estadístico

$$T = \frac{\hat{\beta} - \beta_0}{\sqrt{\text{var}(\hat{\beta})}} \xrightarrow{D} N(0, 1).$$

Es conocido que, cuando $\eta(\beta)$ es no lineal en β , el estadístico W **no es invariante** a la parametrización, y por tanto, formas equivalentes para $\eta(\beta)$, puede llevar a valores diferentes de W .



- **Test score:** El estadístico score (de Rao) es definido por

$$R = \mathbf{U}(\boldsymbol{\beta}_0)^\top \text{Cov}(\boldsymbol{\beta}_0) \mathbf{U}(\boldsymbol{\beta}_0),$$

donde $\text{Cov}(\boldsymbol{\beta}_0)$ corresponde a la matriz de covarianza de $\hat{\boldsymbol{\beta}}$ que debe ser estimada bajo H_0 .

Para GLMs, obtenemos

$$R = \phi^{-1} \mathbf{U}(\boldsymbol{\beta}_0)^\top (\mathbf{X}^\top \mathbf{W}_0 \mathbf{X})^{-1} \mathbf{U}(\boldsymbol{\beta}_0) \xrightarrow{D} \chi^2(p).$$

donde $\mathbf{W} = \text{diag}(\omega_1, \dots, \omega_n)$ es evaluada en $\boldsymbol{\beta} = \boldsymbol{\beta}_0$. De este modo, también podemos escribir

$$R = \phi(\mathbf{Y} - \boldsymbol{\mu}_0)^\top \mathbf{V}_0^{-1/2} \mathbf{H}_0 \mathbf{V}_0^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}_0),$$

con $\mathbf{H} = \mathbf{W}^{1/2} \mathbf{X} (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{1/2}$.



- **Test F :** Para el caso de hipótesis simples el estadístico F adopta la forma:

$$F = \frac{\{D(\mathbf{y}; \boldsymbol{\mu}_0) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})\}/p}{D(\mathbf{y}; \hat{\boldsymbol{\mu}})/(n - p)}$$

que, bajo H_0 y cuando $\phi \rightarrow \infty$, tiene una distribución $F(p, n - p)$.

Observaciones:

- Tenemos también que

$$F \xrightarrow{D} F(p, n - p),$$

cuando usamos un estimador consistente de ϕ^{-1} .

- El estadístico F también es invariante por reparametrizaciones.
- Finalmente, el estadístico F no depende del parámetro de dispersión ϕ^{-1} .



Ejemplo (caso normal):

Para el caso normal, tenemos

$$\mathcal{F}(\beta) = \frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X}, \quad \mathbf{U}(\beta) = \frac{1}{\sigma^2} \mathbf{X}^\top (\mathbf{Y} - \boldsymbol{\mu}).$$

De este modo:

$$LR = \frac{1}{\sigma^2} \left\{ \sum_{i=1}^n (y_i - \mu_{0i})^2 - \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 \right\},$$

$$W = \frac{1}{\sigma^2} (\hat{\beta} - \beta_0)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta_0),$$

$$R = \frac{1}{\sigma^2} (\mathbf{Y} - \boldsymbol{\mu}_0)^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{Y} - \boldsymbol{\mu}_0),$$

$$F = \frac{1}{qs^2} \left\{ \sum_{i=1}^n (y_i - \mu_{0i})^2 - \sum_{i=1}^n (y_i - \hat{\mu}_i)^2 \right\}.$$



Una **región de confianza asintótica** de tamaño $1 - \alpha$ para β basada en el **estadístico de Wald**, es dada por:

$$RC_W(\beta) = \{\beta : (\hat{\beta} - \beta)^\top \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X} (\hat{\beta} - \beta) \leq \phi^{-1} \chi_{1-\alpha}^2(p)\}.$$

donde $\chi_{1-\alpha}^2(p)$ denota el valor cuantil $1 - \alpha$ de la distribución chi-cuadrado con p grados de libertad.

La región de confianza basada en el estadístico de Wald, puede depender de la parametrización.³ En cuyo caso, puede ser recomendable usar **estadísticas invariantes**. Por ejemplo,

$$RC_{LR}(\beta) = \{\beta : 2[\ell(\hat{\beta}) - \ell(\beta)] \leq \chi_{1-\alpha}^2(p)\}.$$

³Cuando η es no lineal.



Considere hipótesis lineales del tipo

$$H_0 : C\beta = \mathbf{0} \quad \text{versus} \quad H_1 : C\beta \neq \mathbf{0},$$

donde C es matriz de contrastes de orden $k \times p$ con $\text{rk}(C) = k$.

Evidentemente $\hat{\beta}$ coincide con el estimador bajo $H_1 : C\beta \neq \mathbf{0}$. Mientras que la estimación bajo H_0 requiere, en general, de un procedimiento iterativo

$$\tilde{\beta}^{(r+1)} = \tilde{\beta}^{(r)} - (X^\top W^{(r)} X)^{-1} C^\top \{C(X^\top W^{(r)} X)^{-1} C^\top\}^{-1} C \tilde{\beta}^{(r)},$$

para $r = 0, 1, \dots$ con matriz de covarianza

$$\text{Cov}(\tilde{\beta}) = \phi^{-1} (X^\top W X)^{-1} [I - C^\top \{C(X^\top W X)^{-1} C^\top\}^{-1} C]^{-1} (X^\top W X)^{-1}.$$



Para hipótesis lineales del tipo $H_0 : C\beta = 0$, tenemos

$$LR = \phi\{D(\mathbf{y}; \tilde{\boldsymbol{\mu}}) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})\},$$

donde $\tilde{\boldsymbol{\mu}}$ denota el MLE de $\boldsymbol{\mu}$ bajo $H_0 : C\beta = 0$. Mientras que

$$R = \phi^{-1} \mathbf{U}^\top (\tilde{\boldsymbol{\beta}}) (\mathbf{X}^\top \tilde{\mathbf{W}} \mathbf{X})^{-1} \mathbf{U} (\tilde{\boldsymbol{\beta}}),$$

con $\tilde{\mathbf{W}}$ es evaluada en $\tilde{\boldsymbol{\beta}}$. Por otro lado,

$$\begin{aligned} W &= (C\hat{\boldsymbol{\beta}} - 0)^\top \{\text{Cov}(C\hat{\boldsymbol{\beta}})\}^{-1} (C\hat{\boldsymbol{\beta}} - 0) \\ &= \phi(C\hat{\boldsymbol{\beta}})^\top \{C(\mathbf{X}^\top \hat{\mathbf{W}} \mathbf{X})^{-1} C^\top\}^{-1} C\hat{\boldsymbol{\beta}}. \end{aligned}$$

Además,

$$LR \xrightarrow{D} \chi^2(k), \quad W \xrightarrow{D} \chi^2(k), \quad R \xrightarrow{D} \chi^2(k).$$



El estadístico F para hipótesis lineales de la forma $H_0 : C\beta = 0$ adopta la forma:

$$F = \frac{\{D(\mathbf{y}; \tilde{\boldsymbol{\mu}}) - D(\mathbf{y}; \hat{\boldsymbol{\mu}})\}/k}{D(\mathbf{y}; \hat{\boldsymbol{\mu}})/(n-p)},$$

que tiene una distribución $F(k, n-p)$ cuando $\phi \rightarrow \infty$. Es posible mostrar que

$$D(\mathbf{y}; \tilde{\boldsymbol{\mu}}) - D(\mathbf{y}; \hat{\boldsymbol{\mu}}) = (C\hat{\boldsymbol{\beta}})^\top \{C(\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} C^\top\}^{-1} C\hat{\boldsymbol{\beta}}.$$



Observación:

- Suponga la hipótesis

$$H_0 : C\beta = \mathbf{0}, \quad \text{versus} \quad H_1 : C\beta \geq \mathbf{0},$$

en ese caso los estadísticos LR , W , R tienen una distribución de mezcla de variables chi-cuadrado.

- Suponga el modelo:

$$\eta = X\beta + \gamma d_i,$$

con $d_i = (\mathbf{0}, 1, \mathbf{0})^\top$. La hipótesis

$$H_0 : \gamma = 0, \quad \text{versus} \quad H_1 : \gamma \neq 0,$$

ofrece una interesante interpretación para el estadístico t .

