

MAT-466: Diagnóstico de influencia en GLM

Felipe Osorio

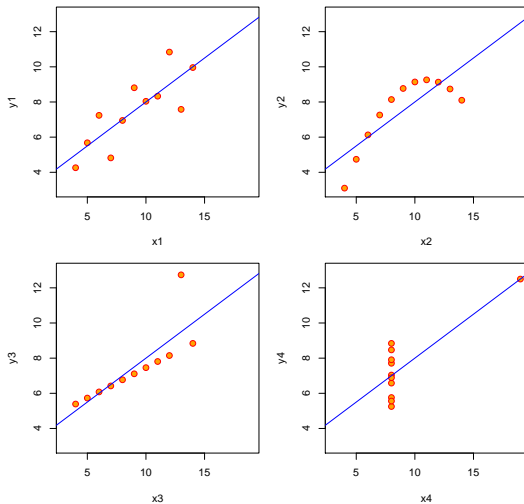
fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Cuarteto de regresiones “idénticas” de Anscombe (1973)

Anscombe's 4 Regression data sets



Distancia de Cook (1977)

Basado en el elipsoide de confianza del $(1 - \alpha)100\%$ para β ,

$$\frac{(\beta - \hat{\beta})^\top \mathbf{X}^\top \mathbf{X} (\beta - \hat{\beta})}{ps^2} \leq F_{p, n-p}(1 - \alpha).$$

Cook (1977) propuso **determinar la influencia** de la i -ésima observación, usando

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta}_{(i)} - \hat{\beta})}{ps^2}, \quad i = 1, \dots, n.$$

Cook (1977) recomienda comparar D_i con algún percentil de la distribución $F_{p, n-p}$ ($\alpha = 0.10$). Weisberg (1985) sugiere que puede ser más razonable usar $\alpha = 0.50$ y propone que $D_i > 1$ es un **indicador de observaciones influyentes**.



Evaluando la distancia de Cook

Considere

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(i)} \\ \mathbf{x}_i^\top \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} \mathbf{Y}_{(i)} \\ Y_i \end{pmatrix}.$$

Luego de un poco de álgebra, tenemos que

$$\begin{aligned} \hat{\beta}_{(i)} &= (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{Y}_{(i)} \\ &= \hat{\beta} - \frac{e_i}{1 - h_i} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i, \end{aligned}$$

esto permite escribir D_i como

$$D_i = \frac{r_i^2}{p} \left(\frac{h_i}{1 - h_i} \right), \quad i = 1, \dots, n,$$

que es una fórmula bastante [agradable desde el punto de vista computacional](#).



Considere que una distribución F es **contaminada** por una distribución con masa unitaria en z , digamos δ_z . Es decir,

$$F(\epsilon) = (1 - \epsilon)F + \epsilon\delta_z.$$

Hampel (1968, 1974) propuso medir la **influencia de la i -ésima observación** mediante

$$\text{IF}(z; F, T) = \lim_{\epsilon \rightarrow 0} \frac{T(F(\epsilon)) - T(F)}{\epsilon},$$

donde $T(\cdot)$ es una estadística vector-valorada basada en una muestra aleatoria desde la cdf F .



Considere el modelo de regresión lineal y sea \hat{F} la función de distribución empírica basada en la muestra, tomando $T(\hat{F}) = \hat{\beta}$, se obtiene la **curva de influencia empírica**

$$EIC(\mathbf{x}, Y) = n(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}(Y - \mathbf{x}^\top \hat{\beta}),$$

de este modo, $EIC_i(\mathbf{x}_i, Y_i) = n(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i e_i$.

Sea $\hat{F}_{(i)}$ la cdf muestral con el i -ésimo caso eliminado, y $T(\hat{F}_{(i)}) = \hat{\beta}_{(i)}$, entonces

$$EIC_{(i)}(\mathbf{x}_i, Y_i) = (n-1)(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i e_i / (1 - h_i)^2.$$



Una **versión muestral de la curva de influencia** (SIC) es hallada mediante omitir en límite en la definición de la IF y tomar $F = \hat{F}$, $T(\hat{F}) = \hat{\beta}$ y $\epsilon = -1/(n-1)$.

Evalando en $\mathbf{z}_i = (\mathbf{x}_i, Y_i)$ tenemos $(1 - \epsilon)\hat{F} + \epsilon\delta_{\mathbf{z}_i} = \hat{F}_{(i)}$

$$\begin{aligned} SIC_i &= -(n-1)(T(\hat{F}_{(i)}) - T(\hat{F})) \\ &= (n-1)(\hat{\beta} - \hat{\beta}_{(i)}) \\ &= (n-1) \frac{e_i}{1 - h_i} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i e_i. \end{aligned}$$

Típicamente se considera

$$IF_i = (n-1)^{-1} SIC_i = \hat{\beta} - \hat{\beta}_{(i)},$$

como la **curva de influencia muestral**.



Cook y Weisberg (1980) propusieron normalizar la IF_i como

$$D_i(M, c) = \frac{(IF_i)^\top M (IF_i)}{c} = \frac{(\hat{\beta} - \hat{\beta}_{(i)})^\top M (\hat{\beta} - \hat{\beta}_{(i)})}{c},$$


donde M es matriz definida positiva $p \times p$ y $c > 0$ es un factor de escala.

Algunas medidas de influencia:

M	c	Medida	Referencia
$X^\top X$	ps^2	D_i	Cook (1977)
$X^\top X$	$ps_{(i)}^2$	$(DFFITs_i)^2$	Welsch y Kuh (1977)

Distancia de Cook: Datos de Anscombe (1973)

Cook's distance plots. Anscombe's data sets



Medidas basadas en diferenciación (Pregibon, 1981)

Considere el modelo

$$Y_j = \mathbf{x}_j^\top \boldsymbol{\beta} + \epsilon_j, \quad j = 1, \dots, n,$$

donde $\text{var}(\epsilon_i) = \sigma^2/\omega$, $0 \leq \omega \leq 1$ y $\text{var}(\epsilon_j) = \sigma^2$, para $j \neq i$. En este caso

$$\widehat{\boldsymbol{\beta}}(\omega) = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{Y} = \widehat{\boldsymbol{\beta}} - \frac{(1-\omega)e_i}{1 - (1-\omega)h_i} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i,$$

donde $\mathbf{W} = \text{blc diag}(\mathbf{I}_{n-1}, \omega)$.

Note que

$$\begin{aligned} \widehat{\boldsymbol{\beta}}(1) - \widehat{\boldsymbol{\beta}}(0) &= \frac{e_i}{1 - h_i} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i \\ &= \widehat{\boldsymbol{\beta}} - \widehat{\boldsymbol{\beta}}_{(i)} = \text{IF}_i. \end{aligned}$$



Medidas basadas en diferenciación (Pregibon, 1981)

El efecto de la perturbación en la varianza puede ser obtenido como

$$\frac{\partial \hat{\beta}(\omega)}{\partial \omega} = \frac{e_i}{\{1 - (1 - \omega)h_i\}^2} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i.$$

En particular,

$$\left. \frac{\partial \hat{\beta}(\omega)}{\partial \omega} \right|_{\omega=1} = e_i (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i,$$

describe un cambio local sobre $\hat{\beta}(\omega)$ en la solución LS.

Medidas de diagnóstico pueden ser construídas de manera similar que usando procedimientos de eliminación de casos.



Comparando matrices de covarianza

Considere comparar $\text{Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ con la **matriz de covarianza que resulta de eliminar el i -ésimo caso**. Esto lleva a (Belsley, Kuh y Welsch, 1980)

$$\begin{aligned} COVRATIO_i &= \frac{\det\{s_{(i)}^2(\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1}\}}{\det\{s^2(\mathbf{X}^\top \mathbf{X})^{-1}\}} = \left(\frac{s_{(i)}^2}{s^2}\right)^p \frac{\det(\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1}}{\det(\mathbf{X}^\top \mathbf{X})^{-1}} \\ &= \frac{1}{1 - h_i} \left(\frac{n - p - r_i^2}{n - p - 1}\right)^p, \end{aligned}$$

se ha planteado como punto de corte $|COVRATIO_i - 1| > 3p/n$.



Repertorio de medidas de influencia

Existe un repertorio bastante extenso de medidas de influencia, por ejemplo:

Medida

$$D_i = \frac{r_i^2}{p} \left(\frac{h_i}{1-h_i} \right)$$

$$DFFITs_i = |t_i| \sqrt{\frac{h_i}{1-h_i}}$$

$$AK_i = DFFITS_i \sqrt{\frac{n-p}{p}}$$

$$W_i = DFFITS_i \sqrt{\frac{n-1}{1-h_i}}$$

$$COVRATIO_i = \frac{1}{1-h_i} \left(\frac{n-p-r_i^2}{n-p-1} \right)^p$$

$$h_i = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i$$

$$r_i = \frac{e_i}{s \sqrt{1-h_i}}$$

$$t_i = r_i \sqrt{\frac{n-p-1}{n-p-r_i^2}}$$

Punto de corte

$$F_{p, n-p}(1-\alpha)$$

$$2\sqrt{p/n}$$

$$2\sqrt{(n-p)/n}$$

$$3\sqrt{p}$$

$$|COVRATIO_i - 1| > 3p/n$$

$$2p/n$$

$$\approx N(0, 1)$$

$$\approx t_{n-p-1}$$



Belsley, Kuh y Welsch (1981) y Velleman y Welsch (1981) han discutido **estrategías para amenizar el cálculo** de estas medidas de influencia.

Para modelos de regresión lineal algunas de estas medidas han sido **implementadas en software estadístico** tal como SAS, SPSS, S-PLUS/R.

En particular, R (o S-PLUS) disponen de las funciones **lm.influence** y **ls.diag** asociadas con las funciones **lm** (o **glm**) y **lsfit**, respectivamente.

La función **lm.influence** dispone de las siguientes medidas:

<code>rstandard</code>	<code>rstudent</code>	<code>dffits</code>	<code>dfbetas</code>
<code>covratio</code>	<code>cooks.distance</code>	<code>hatvalues</code>	

Estas cantidades **pueden ser escritas de forma eficiente** usando la descomposición QR o SVD.



Distancia de Cook generalizada

Considere $\hat{\theta}_{(i)}$ la estimación ML de θ cuando se elimina el i -ésimo caso, es decir $\hat{\theta}_{(i)}$ maximiza la log-verosimilitud

$$\ell_{(i)}(\theta) = \sum_{j \neq i} \ell_j(\theta),$$

Podemos usar la aproximación

$$\ell_{(i)}(\theta) \approx \ell_{(i)}(\hat{\theta}) + (\theta - \hat{\theta})^\top U_{(i)}(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^\top \ddot{\ell}_{(i)}(\hat{\theta})(\theta - \hat{\theta}),$$

donde $U_{(i)}(\hat{\theta}) = \partial \ell_{(i)}(\theta) / \partial \theta|_{\theta=\hat{\theta}}$ y $\ddot{\ell}_{(i)}(\hat{\theta}) = \partial^2 \ell_{(i)}(\theta) / \partial \theta \partial \theta^\top|_{\theta=\hat{\theta}}$.

Si $-\ddot{\ell}_{(i)}(\hat{\theta})$ es definida positiva, la aproximación cuadrática es maximizada en

$$\hat{\theta}_{(i)}^1 = \hat{\theta} + \{-\ddot{\ell}_{(i)}(\hat{\theta})\}^{-1} U_{(i)}(\hat{\theta}),$$

que es una **aproximación de un paso** para $\hat{\theta}_{(i)}$ (Cook y Weisberg, 1982).



Distancia de Cook generalizada

Notando que

$$\mathbf{0} = \mathbf{U}(\hat{\boldsymbol{\theta}}) = \left. \frac{\partial \ell_{(i)}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}} + \left. \frac{\partial \ell_i(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}},$$

podemos escribir $\mathbf{U}_{(i)}(\hat{\boldsymbol{\theta}}) = -\mathbf{U}_i(\hat{\boldsymbol{\theta}})$.

De este modo

$$\hat{\boldsymbol{\theta}}_{(i)}^1 - \hat{\boldsymbol{\theta}} = -\{\ddot{\ell}_{(i)}(\hat{\boldsymbol{\theta}})\}^{-1} \mathbf{U}_i(\hat{\boldsymbol{\theta}}).$$

Una aproximación adicional, lleva a la [distancia de Cook generalizada](#)

$$\begin{aligned} GD_i^1 &= (\hat{\boldsymbol{\theta}}_{(i)}^1 - \hat{\boldsymbol{\theta}})^\top \{\ddot{\ell}(\hat{\boldsymbol{\theta}})\}^{-1} (\hat{\boldsymbol{\theta}}_{(i)}^1 - \hat{\boldsymbol{\theta}}) \\ &= \mathbf{U}_i^\top(\hat{\boldsymbol{\theta}}) \{\ddot{\ell}(\hat{\boldsymbol{\theta}})\}^{-1} \mathbf{U}_i(\hat{\boldsymbol{\theta}}). \end{aligned}$$



Desplazamiento de verosimilitudes

Sea $\ell(\boldsymbol{\theta})$ la log-verosimilitud de los datos completos. Cook y Weisberg (1982) definieron el **desplazamiento de verosimilitudes** como

$$LD_i = 2\{\ell(\hat{\boldsymbol{\theta}}) - \ell(\hat{\boldsymbol{\theta}}_{(i)})\},$$

o, usando una aproximación de un paso

$$LD_i^1 = 2\{\ell(\hat{\boldsymbol{\theta}}) - \ell(\hat{\boldsymbol{\theta}}_{(i)}^1)\}.$$

Las medidas LD_i y LD_i^1 pueden ser interpretadas en términos de la **región de confianza asintótica**

$$\{\boldsymbol{\theta} : 2\{\ell(\hat{\boldsymbol{\theta}}) - \ell(\boldsymbol{\theta})\} \leq \chi_q^2(1 - \alpha)\},$$

donde $\chi_q^2(1 - \alpha)$ es un valor cuantil de la distribución chi-cuadrado con q grados de libertad y q denota la dimensión de $\boldsymbol{\theta}$.



Considere la siguiente aproximación usando la expansión de Taylor de $\ell(\hat{\boldsymbol{\theta}}_{(i)})$ en torno de $\hat{\boldsymbol{\theta}}$

$$\ell(\hat{\boldsymbol{\theta}}_{(i)}) \approx \ell(\hat{\boldsymbol{\theta}}) + (\hat{\boldsymbol{\theta}}_{(i)} - \hat{\boldsymbol{\theta}})^\top \mathbf{U}(\hat{\boldsymbol{\theta}}) + \frac{1}{2}(\hat{\boldsymbol{\theta}}_{(i)} - \hat{\boldsymbol{\theta}})^\top \ddot{\ell}(\hat{\boldsymbol{\theta}})(\hat{\boldsymbol{\theta}}_{(i)} - \hat{\boldsymbol{\theta}}),$$

como $\mathbf{U}(\hat{\boldsymbol{\theta}}) = \mathbf{0}$, tenemos que

$$LD_i \approx (\hat{\boldsymbol{\theta}}_{(i)} - \hat{\boldsymbol{\theta}})^\top \{-\ddot{\ell}(\hat{\boldsymbol{\theta}})\}^{-1} (\hat{\boldsymbol{\theta}}_{(i)} - \hat{\boldsymbol{\theta}}) = GD_i.$$

Se puede obtener una aproximación diferente substituyendo la matriz de información observada $-\ddot{\ell}(\hat{\boldsymbol{\theta}})$ por la **matriz de información esperada**.



Cook (1986) sugiere estudiar el efecto de introducir **pequeñas perturbaciones** en el modelo (o datos).

Sea $\omega \in \Omega$ un **vector de perturbación** $q \times 1$. Considere el modelo perturbado

$$\mathcal{M} = \{f(\mathbf{Y}; \boldsymbol{\theta}, \omega) : \omega \in \Omega\},$$

donde $f(\mathbf{Y}; \boldsymbol{\theta}, \omega)$ representa la función de densidad de $\mathbf{Y} = (\mathbf{Y}_1^\top, \dots, \mathbf{Y}_n^\top)^\top$ perturbada por ω y función de **log-verosimilitud perturbada**

$$\ell(\boldsymbol{\theta}, \omega) = \log f(\mathbf{Y}; \boldsymbol{\theta}, \omega).$$

Suponga también que existe un vector de no perturbación ω_0 , tal que

$$\ell(\boldsymbol{\theta}, \omega_0) = \ell(\boldsymbol{\theta}).$$



Sea $\hat{\theta}(\omega)$ el estimador máximo verosímil de θ bajo el modelo perturbado \mathcal{M} .

La comparación entre $\hat{\theta}$ y $\hat{\theta}(\omega)$ es una manera de **determinar la influencia de una perturbación particular ω** .

Si la “diferencia” entre $\hat{\theta}$ y $\hat{\theta}(\omega)$ es pequeña conforme ω varía en Ω . Entonces el análisis es **estable**.

El procedimiento es suficientemente flexible, pues **permite perturbar tanto los datos como el modelo**.



Para fijar ideas, suponga el modelo de regresión $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, $\boldsymbol{\epsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I})$.

1. **Perturbación de respuesta:** considere substituir \mathbf{Y} por

$$\mathbf{Y}(\boldsymbol{\omega}) = \mathbf{Y} + \boldsymbol{\omega}, \quad \boldsymbol{\omega}_0 = \mathbf{0}.$$

2. **Perturbación de predictores:** donde para el j -ésimo regresor,

$$\mathbf{X}(\boldsymbol{\omega}) = \mathbf{X} + \boldsymbol{\omega} \mathbf{d}_j^\top, \quad \boldsymbol{\omega}_0 = \mathbf{0},$$

donde \mathbf{d}_j tiene un 1 en la j -ésima posición y ceros en las restantes.

3. **Perturbación de casos:** los disturbios aleatorios son reemplazados por

$$\boldsymbol{\epsilon}(\boldsymbol{\omega}) \sim N_n(\mathbf{0}, \sigma^2 \mathbf{W}), \quad \mathbf{W} = \text{diag}(\boldsymbol{\omega}), \quad \boldsymbol{\omega}_0 = \mathbf{1}_n.$$



Comparar $\hat{\theta}$ con $\hat{\theta}(\omega)$ conforme ω varia en Ω no es necesariamente una tarea simple.

Cook (1986) sugirió usar el **desplazamiento de verosimilitudes**

$$LD(\omega) = 2\{\ell(\hat{\theta}) - \ell(\hat{\theta}(\omega))\},$$

para medir la influencia de una perturbación sobre el MLE de θ .

$LD(\omega)$ es siempre no negativo y mide la diferencia entre $\hat{\theta}$ y $\hat{\theta}(\omega)$ mediante usar los contornos de la log-verosimilitud $\ell(\theta)$ para el **modelo no perturbado**.

La log-verosimilitud del modelo perturbado $\ell(\theta, \omega)$ **sólo es utilizada para proveer el estimador $\hat{\theta}(\omega)$** , no interviene en el cálculo de $LD(\omega)$.



La idea de influencia local (Cook, 1986) está interesada en **caracterizar el comportamiento local** de $LD(\omega)$ en torno de ω_0 .

Cook (1986) mostró que la curvatura normal $C_h(\theta)$ usada para caracterizar $LD(\omega_0 + a\mathbf{h})$ en torno de $a = 0$ con $\|\mathbf{h}\| = 1$ asume la forma

$$C_h(\theta) = 2\mathbf{h}^\top \{-\ddot{\mathbf{F}}\}\mathbf{h},$$

donde $\ddot{\mathbf{F}} = \partial^2 \ell(\theta(\omega)) / \partial \omega \partial \omega^\top |_{\omega=\omega_0}$.

Es posible notar que $-\ddot{\mathbf{F}} = \Delta^\top \{-\ddot{\ell}(\hat{\theta})\}^{-1} \Delta$, donde

$$\ddot{\ell}(\hat{\theta}) = \frac{\partial^2 \ell(\theta)}{\partial \theta \partial \theta^\top} \Big|_{\theta=\hat{\theta}} \quad \text{y} \quad \Delta = \frac{\partial^2 \ell(\theta, \omega)}{\partial \theta \partial \omega^\top} \Big|_{\theta=\hat{\theta}, \omega=\omega_0}.$$



Cook (1986) sugirió prestar atención a la **dirección de máxima curvatura** h_{\max} .

h_{\max} indica **cómo se debe perturbar el modelo** para obtener el mayor cambio local en el desplazamiento de verosimilitudes.

La máxima curvatura $C_{h_{\max}}(\theta)$ está dada por el mayor valor propio de \ddot{F} (en valor absoluto) y la dirección de mayor curvatura h_{\max} está dada por el vector propio asociado.

Otras direcciones también pueden ser de interés, por ejemplo $h_{2\text{nd}}$. Lesaffre y Verbeke (1998) sugieren realizar el gráficos de índices de $C_i = C_{h_i}(\theta)$, donde h_i es un vector con un 1 en la posición i -ésima y ceros en las restantes.



En ocasiones se tiene interés en determinar la **influencia de un subconjunto** θ_1 de $\theta = (\theta_1^\top, \theta_2^\top)^\top$. En este caso,

$$LD(\omega) = 2\{\ell(\hat{\theta}) - \ell(\hat{\theta}_1(\omega), \hat{\theta}_2(\hat{\theta}_1(\omega)))\},$$

donde $\hat{\theta}_1(\omega), \hat{\theta}_2(\hat{\theta}_1(\omega))$ es el MLE de θ_2 en el modelo perturbado, para θ_1 fijado. Considere las matrices

$$\ddot{\ell}(\theta) = \begin{pmatrix} \ddot{\ell}_{\theta_1\theta_1}(\theta) & \ddot{\ell}_{\theta_1\theta_2}(\theta) \\ \ddot{\ell}_{\theta_2\theta_1}(\theta) & \ddot{\ell}_{\theta_2\theta_2}(\theta) \end{pmatrix} \quad \text{y} \quad B_{22} = \begin{pmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \ddot{\ell}_{\theta_2\theta_2}^{-1}(\theta) \end{pmatrix}.$$

Entonces, la **curvatura normal** en la dirección h para θ_1 asume la forma

$$C_h(\theta_1) = -2h^\top \Delta^\top \{\ddot{\ell}^{-1}(\theta) - B_{22}\} \Delta h.$$



Dependencia de escala de la curvatura normal

Considere la función de influencia $T(\omega)$. La forma general para la curvatura normal es

$$C_h(\theta) = \frac{\mathbf{h}^\top \ddot{\Gamma} \mathbf{h}}{\mathbf{h}^\top (\mathbf{I} + \dot{\Gamma} \dot{\Gamma}^\top) \mathbf{h} (1 + \dot{\Gamma}^\top \dot{\Gamma})^{1/2}},$$

donde $\dot{\Gamma} = \partial \hat{T}(\omega) / \partial \omega|_{\omega=\omega_0}$ y $\ddot{\Gamma} = \partial^2 \hat{T}(\omega) / \partial \omega \partial \omega^\top|_{\omega=\omega_0}$.

En influencia local usando el desplazamiento de verosimilitudes se tiene

$$\dot{\Gamma} = 2\partial \ell(\hat{\theta}_\omega) / \partial \omega|_{\omega=\omega_0} = \mathbf{0}.$$

Fung y Kwan (1993) mostraron que $C_h(\theta)$ no es invariante bajo transformaciones de escala de $T(\omega)$.



Poon y Poon (1999) propusieron la **curvatura normal conformal**

$$B_h(\theta) = \frac{1}{h^\top (I + \dot{\Gamma} \dot{\Gamma}^\top) h} \frac{h^\top \ddot{\Gamma} h}{\{\text{tr} \ddot{\Gamma}^2\}^{1/2}} \Big|_{\omega=\omega_0}.$$

En particular, usando el desplazamiento de verosimilitudes

$$B_h(\theta) = \frac{h^\top \Delta^\top \{-\ddot{\ell}(\theta)\}^{-1} \Delta h}{\sqrt{\text{tr}\{\Delta^\top \{-\ddot{\ell}(\theta)\}^{-1} \Delta\}^2}} \Big|_{\theta=\hat{\theta}, \omega=\omega_0}.$$



Observación:

Considere una reparametrización $\phi : \Omega \rightarrow \Theta$ tal que la matriz Jacobiana de ϕ es no singular. Una matriz M se dice conformal si existe $\tau > 0$ tal que $MM^T = \tau I$. De este modo, una **reparametrización es dicha conformal** en ω_0 si su matriz Jacobiana en ω_0 es conformal.

Propiedades:

- (a) La curvatura normal conformal (Poon y Poon, 1999) es invariante bajo reparametrizaciones conformales.
- (b) Para cualquier dirección h , $B_h(\theta)$ satisface que $0 \leq |B_h(\theta)| \leq 1$.



Bench-mark para la curvatura normal

Considere la descomposición espectral

$$\ddot{\mathbf{F}} = \sum_{i=1}^q \lambda_i \mathbf{u}_i \mathbf{u}_i^\top,$$

donde $\{\lambda_i, \mathbf{u}_i\}_{i=1}^q$ son los valores y vectores propios de $\ddot{\mathbf{F}}$ con $\mathbf{u}_i = (u_{i1}, \dots, u_{iq})^\top$.
Se tiene que $\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_q = 0$, sea

$$\tilde{\lambda}_i = \frac{\lambda_i}{\sum_{k=1}^r \lambda_k}, \quad \text{y} \quad \sum_{i=1}^r \tilde{\lambda}_i = 1.$$

Para \mathbf{h}_j un vector con un 1 en la j -ésima posición y ceros en las restantes. Tenemos,

$$B_{h_j}(\boldsymbol{\theta}) = \sum_{i=1}^r \lambda_i u_{ij}^2.$$



Zhu y Lee (2001) definieron $M(0)_j = B_{h_j}(\boldsymbol{\theta})$ y notaron que

$$\overline{M}(0) = 1/q.$$

Ellos propusieron **declarar la j -ésima observación como influyente** si $B_{h_j}(\boldsymbol{\theta})$ es mayor que el punto de corte

$$\overline{M}(0) + 2 SM(0),$$

donde $SM(0)$ es el error estándar muestral de $\{M(0)_k, k = 1, \dots, q\}$.



El cálculo de \mathbf{h}_{\max} involucra la **descomposición espectral** de la matriz

$$\ddot{\mathbf{F}} = \mathbf{\Delta}^\top \{-\ddot{\ell}(\hat{\boldsymbol{\theta}})\}^{-1} \mathbf{\Delta},$$

que puede ser de **alto costo computacional**.

Una alternativa es considerar $\{-\ddot{\ell}(\hat{\boldsymbol{\theta}})\} = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top$ y hacer $\mathbf{B} = \mathbf{\Delta}^\top \mathbf{\Gamma} \mathbf{\Lambda}^{-1/2}$. Luego, realizamos una descomposición valor singular de $\mathbf{B} = \mathbf{U} \mathbf{D} \mathbf{V}^\top$. Entonces,

$$\ddot{\mathbf{F}} = \mathbf{B} \mathbf{B}^\top = \mathbf{U} \mathbf{D}^2 \mathbf{U}^\top = \sum_{j=1}^r \delta_j \mathbf{u}_j \mathbf{u}_j^\top,$$

donde $\mathbf{U} = (\mathbf{u}_1, \dots, \mathbf{u}_r) \in \mathbb{R}^q \times r$, es ortogonal por columnas y $\mathbf{D} = \text{diag}(\delta_1^{1/2}, \dots, \delta_r^{1/2})$. Note que

$$\mathbf{h}_{\max} = \mathbf{u}_1, \quad \text{y} \quad B_h(\boldsymbol{\theta}) = \frac{\mathbf{h}^\top \mathbf{U} \mathbf{D}^2 \mathbf{U}^\top \mathbf{h}}{\text{tr } \mathbf{D}^2}.$$



Billor y Loynes (1993) consideran la siguiente **función de influencia**

$$LD^*(\omega) = -2\{\ell(\hat{\theta}) - \ell(\hat{\theta}(\omega), \omega)\}.$$

Se desea caracterizar la superficie $(\omega, LD^*(\omega))$ para perturbaciones del tipo $\omega = \omega_0 + a\mathbf{h}$ donde ω_0 es la perturbación nula, \mathbf{h} es un vector unitario y el escalar a determina la magnitud de la perturbación.

En este caso **la primera derivada provee información relevante** del comportamiento local de $LD^*(\omega)$ en torno de ω_0 .

La influencia local de una perturbación es medida usando **la pendiente** en la dirección \mathbf{h} , denotada por S_h

$$S_h = \left. \frac{\partial LD^*(\omega)}{\partial a} \right|_{a=0}.$$



Note que

$$S_h = \left. \frac{\partial LD^*(\omega)}{\partial a} \right|_{a=0} = \mathbf{h}^\top \left. \frac{\partial LD^*(\omega)}{\partial \omega} \right|_{a=0},$$

usando la regla de la cadena, se tiene que

$$S_h = \mathbf{h}^\top \left\{ \frac{\partial \ell(\hat{\boldsymbol{\theta}}(\omega), \omega)}{\partial \omega} + \frac{\partial \ell(\boldsymbol{\theta}, \omega)}{\partial \boldsymbol{\theta}} \frac{\partial \hat{\boldsymbol{\theta}}(\omega)}{\partial \omega} \right\} \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}, \omega=\omega_0}.$$

Finalmente, esto reduce a

$$S_h = 2\mathbf{h}^\top \left. \frac{\partial \ell(\boldsymbol{\theta}, \omega)}{\partial \omega} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}, \omega=\omega_0},$$

y la **dirección de máxima pendiente** está dada por

$$\mathbf{h}_{\max} = 2 \left. \frac{\partial \ell(\hat{\boldsymbol{\theta}}, \omega)}{\partial \omega} \right|_{\omega=\omega_0}.$$

Algunos antecedentes bibliográficos



Cook, R.D. (1977).

Detection of influential observation in linear regression.

Technometrics **19**, 15-18.



Cook, R.D. and Weisberg, S. (1982).

Residuals and Influence in Regression.

Chapman and Hall, New York.



Cook, R.D. (1986).

Assessment of local influence.

Journal of the Royal Statistical Society, Series B **48**, 133-169.



Billor, N., and Loynes, R.M. (1993).

Local influence: A new approach.

Communications in Statistics - Theory and Methods **22**, 1595-1611.



Poon, W., and Poon, Y.S. (1999).

Conformal normal curvature and assessment of local influence.

Journal of the Royal Statistical Society, Series B **61**, 51-61.



Zhu, H., Ibrahim, J.G., Lee, S., and Zhang, H. (2007).

Perturbation selection and influence measures in local influence analysis.

The Annals of Statistics **35**, 2565-2588.

