

MAT-466: Diagnóstico de influencia en GLM II

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Leverage generalizado

Para el modelo de regresión lineal,

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \epsilon_i, \quad i = 1, \dots, n,$$

podemos definir el leverage, basado en las siguientes propiedades:

- (a) $\text{var}(\hat{Y}_i) = \sigma^2 h_{ii}$.
- (b) $\text{var}(e_i) = \sigma^2(1 - h_{ii})$.
- (c) $h_{ii} = (\mathbf{x}_i - \bar{\mathbf{x}})^\top (\widetilde{\mathbf{X}}^\top \widetilde{\mathbf{X}})^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$.
- (d) $h_{ij} = \partial \hat{Y}_i / \partial Y_j$.

Sin embargo, cada una de estas pueden no ser simple de extender para modelos más complejos.



Suponga \mathbf{Y} vector n -dimensional con densidad conjunta $f(\mathbf{y}; \boldsymbol{\theta})$ y $\boldsymbol{\mu} = E(\mathbf{Y})$, tal que $\boldsymbol{\mu} = \boldsymbol{\mu}(\boldsymbol{\theta})$. Sea $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}(\mathbf{Y})$ y $\hat{\mathbf{Y}} = \boldsymbol{\mu}(\hat{\boldsymbol{\theta}})$.

Wei, Hu y Fung (1998)¹ definieron la **matriz de leverage generalizado** como:

$$GL(\hat{\boldsymbol{\theta}}(\mathbf{Y})) = \frac{\partial \hat{\mathbf{Y}}}{\partial \mathbf{Y}^\top} = \left\{ \frac{\partial \boldsymbol{\mu}}{\partial \boldsymbol{\theta}^\top} \frac{\partial \hat{\boldsymbol{\theta}}(\mathbf{Y})}{\partial \mathbf{Y}^\top} \right\} \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}(\mathbf{Y})}.$$

Resultado 1 (Wei, Hu y Fung, 1998):

Suponga que \mathbf{Y} tiene log-verosimilitud $\ell(\boldsymbol{\theta}; \mathbf{y})$ con segunda derivada continua con respecto a $\boldsymbol{\theta}$ y \mathbf{Y} . Entonces

$$GL(\hat{\boldsymbol{\theta}}(\mathbf{Y})) = \{ \mathbf{D}_\theta (-\dot{\ell}_{\theta\theta})^{-1} \ddot{\ell}_{\theta\mathbf{Y}} \} \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}(\mathbf{Y})},$$

donde $\mathbf{D}_\theta = \partial \boldsymbol{\mu} / \partial \boldsymbol{\theta}^\top$, $\ddot{\ell}_{\theta\theta} = \partial^2 \ell(\boldsymbol{\theta}; \mathbf{y}) / \partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top$ y $\ddot{\ell}_{\theta\mathbf{Y}} = \partial^2 \ell(\boldsymbol{\theta}; \mathbf{y}) / \partial \boldsymbol{\theta} \partial \mathbf{Y}^\top$.

¹Scandinavian Journal of Statistics **25**, 25-37.

Leverage generalizado

Para GLMs con ϕ conocido, tenemos

$$D_{\beta} = \mathbf{B}\mathbf{X}, \quad \mathbf{B} = \text{diag}(d\mu_1/d\eta_1, \dots),$$

y

$$\ddot{\ell}_{\beta Y} = \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \mathbf{Y}^{\top}} = \phi \mathbf{X}^{\top} \mathbf{V}^{-1} \mathbf{B}.$$

Substituyendo $-\ddot{\ell}_{\beta Y}$ por $E(-\ddot{\ell}_{\beta Y})$ obtenemos (aproximadamente)

$$GL(\hat{\beta}) = \hat{\mathbf{B}}\mathbf{X}(\mathbf{X}^{\top} \hat{\mathbf{W}}\mathbf{X})^{-1} \mathbf{X}^{\top} \hat{\mathbf{V}}^{-1} \hat{\mathbf{B}}.$$

Así,

$$GL_{ii}(\hat{\beta}) = \hat{\omega}_i \mathbf{x}_i (\mathbf{X}^{\top} \hat{\mathbf{W}}\mathbf{X})^{-1} \mathbf{x}_i, \quad \omega_i = (d\mu_i/d\eta_i)^2/V_i.$$

Para el enlace canónico, tenemos

$$GL(\hat{\beta}) = \hat{\mathbf{V}}\mathbf{X}(\mathbf{X}^{\top} \hat{\mathbf{V}}\mathbf{X})^{-1} \mathbf{X}^{\top}.$$



También es posible definir el leverage, notando que

$$\widehat{\beta} = (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top \widehat{\mathbf{W}} \widehat{\mathbf{Z}},$$

con $\widehat{\mathbf{Z}} = \widehat{\boldsymbol{\eta}} + \widehat{\mathbf{W}}^{-1/2} \widehat{\mathbf{V}}^{-1/2} (\mathbf{Y} - \widehat{\boldsymbol{\mu}})$. Así, la matriz de proyección asociada a la regresión (ponderada) de \mathbf{X} contra $\widehat{\mathbf{Z}}$ es

$$\widehat{\mathbf{H}} = \widehat{\mathbf{W}}^{1/2} \mathbf{X} (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} \mathbf{X}^\top \widehat{\mathbf{W}}^{1/2}.$$

Es fácil notar que \widehat{h}_{ii} y $GL_{ii}(\widehat{\beta})$ coinciden.



Suponga ϕ conocido. Podemos considerar el desplazamiento de verosimilitudes

$$LD_i = 2\{\ell(\hat{\beta}) - \ell(\hat{\beta}_{(i)})\},$$

que no tiene forma explícita.

Sin embargo, podemos usar una aproximación cuadrática

$$LD_i \approx (\beta - \hat{\beta})^\top \{-\ddot{\ell}_{\beta\beta}(\hat{\beta})\}^{-1} (\beta - \hat{\beta}).$$

Adicionalmente podemos substituir $-\ddot{\ell}_{\beta\beta}(\hat{\beta})$ por su valor esperado, obteniendo

$$LD_i \approx \phi(\hat{\beta} - \hat{\beta}_{(i)})^\top \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X} (\hat{\beta} - \hat{\beta}_{(i)}).$$



Una aproximación de 1-paso para $\hat{\beta}_{(i)}$ es

$$\hat{\beta}_{(i)}^1 = \hat{\beta} + \{-\ddot{\ell}_{\beta\beta}(\beta)\}^{-1} U_{(i)}(\hat{\beta}).$$

Substituyendo $-\ddot{\ell}_{\beta\beta}(\hat{\beta})$ por $\mathcal{F}(\beta)$, sigue que

$$\hat{\beta}_{(i)}^1 = \hat{\beta} - \frac{r_{P_i} \sqrt{\hat{\omega}_i}}{\phi^{-1/2}(1 - \hat{h}_{ii})} (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1} \mathbf{x}_i.$$

Esto lleva a la siguiente aproximación

$$LD_i \approx \left(\frac{\hat{h}_{ii}}{1 - \hat{h}_{ii}} \right) t_{S_i}^2,$$

con t_{S_i} el residuo estandarizado.



Para motivar ideas considere el modelo perturbado,

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{D}^{-1}),$$

con $\mathbf{D} = \text{diag}(\boldsymbol{\delta})$, con $\boldsymbol{\delta} = (\delta_1, \dots, \delta_n)$ y $\boldsymbol{\delta}_0 = \mathbf{1}_n$. Esto lleva a la log-verosimilitud perturbada

$$\begin{aligned} \ell(\boldsymbol{\beta}|\boldsymbol{\delta}) &= -\frac{1}{2} \log |2\pi\sigma^2 \mathbf{D}^{-1}| - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{D} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \\ &= -\frac{n}{2} \log 2\pi\sigma^2 + \frac{1}{2} \sum_{i=1}^n \log \delta_i - \frac{1}{2\sigma^2} \sum_{i=1}^n \delta_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2. \end{aligned}$$

En este caso tenemos

$$-\ddot{\ell}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X}, \quad \boldsymbol{\Delta} = \frac{1}{\sigma^2} \mathbf{X}^\top \text{diag}(\mathbf{e}),$$

donde $\text{diag}(\mathbf{e}) = \text{diag}(e_1, \dots, e_n)$. De este modo, la curvatura normal adopta la forma

$$C_h = \frac{2}{\sigma^2} |\mathbf{h}^\top \text{diag}(\mathbf{e}) \mathbf{H} \text{diag}(\mathbf{e}) \mathbf{h}|,$$

con $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$. De ahí que \mathbf{h}_{\max} es el vector propio dominante de $\mathbf{F} = \text{diag}(\mathbf{e}) \mathbf{H} \text{diag}(\mathbf{e})$.



Para GLMs considere el esquema de perturbación,

$$\ell(\boldsymbol{\beta}|\boldsymbol{\delta}) = \sum_{i=1}^n \delta_i \ell_i(\boldsymbol{\beta}), \quad 0 \leq \delta_i \leq 1.$$

De este modo,

$$\boldsymbol{\Delta} = \phi \mathbf{X}^\top \widehat{\mathbf{W}}^{1/2} \text{diag}(\mathbf{r}_P), \quad \text{diag}(\mathbf{r}_P) = \text{diag}(r_{P_1}, \dots, r_{P_n}),$$

donde $r_{P_i} = (Y_i - \hat{\mu}_i) / \sqrt{\hat{V}_i}$ es el residuo de Pearson. Substituyendo $-\ddot{\ell}_{\beta\beta}$ por

$$C_h = 2|\mathbf{h}^\top \text{diag}(\mathbf{r}_P) \widehat{\mathbf{H}} \text{diag}(\mathbf{r}_P) \mathbf{h}|,$$

Así, debemos calcular direcciones de interés asociadas a la matriz de curvatura $\mathbf{F} = \text{diag}(\mathbf{r}_P) \widehat{\mathbf{H}} \text{diag}(\mathbf{r}_P)$.



Tarea:

- ▶ Obtener la matriz de curvatura para el esquema de perturbación, definido por

$$\mathbf{Y}(\delta) = \mathbf{Y} + \delta.$$

- ▶ Llevar a cabo un reporte con el análisis de diagnóstico usando los datos del estudio de la vasoconstricción transitoria en la piel de los dedos (Finney, 1948)².

Estos datos que han sido analizados en Pregibon (1981)³ y se encuentran disponibles en formato CSV y RDA en el github de la asignatura.

²Biometrika **34**, 320-334.

³Annals of Statistics **9**, 705-724.

