

MAT-466: Quasi-verosimilitud

Felipe Osorio

`fosorios.mat.utfsm.cl`

Departamento de Matemática, UTFSM



Suponga Y variable aleatoria con

$$E(Y) = \mu, \quad \text{var}(Y) = \sigma^2 V(\mu),$$

y $\mu = \mu(\beta)$ con $V(\mu)$ una función conocida. Bajo estas condiciones, la función

$$\Psi(\mu; Y) = \frac{Y - \mu}{\sigma^2 V(\mu)},$$

disfruta de las siguientes propiedades:

$$E(\Psi) = 0, \quad \text{var}(\Psi) = \frac{1}{\sigma^2 V(\mu)}, \quad E\left(-\frac{\partial \Psi}{\partial \mu}\right) = \frac{1}{\sigma^2 V(\mu)}.$$

Esto permite definir la función de quasi-verosimilitud, como:

$$Q(\mu; y) = \frac{1}{\sigma^2} \int_y^\mu \frac{y - t}{V(t)} dt$$



Evidentemente,

$$\Psi(\mu) = \frac{\partial Q(\mu; y)}{\partial \mu} = \frac{y - t}{\sigma^2 V(t)} \Big|_y^\mu = \frac{y - \mu}{\sigma^2 V(\mu)}.$$

Resultado 1 (Wedderburn, 1974)¹:

La función quasi-score, satisface:

- (i) $E\{\Psi(\mu)\} = 0$.
- (ii) $E\left\{\frac{\partial \Psi(\mu)}{\partial \beta_j}\right\} = 0$, para $j = 1, \dots, p$.
- (iii) $E\{\Psi^2(\mu)\} = E(-\partial \Psi(\mu)/\partial \mu) = \sigma^{-2}/V(\mu)$.
- (iv) $E\left\{\frac{\partial \Psi(\mu)}{\partial \beta_r} \frac{\partial \Psi(\mu)}{\partial \beta_s}\right\} = E\left(-\frac{\partial^2 \Psi(\mu)}{\partial \beta_r \partial \beta_s}\right) = \frac{1}{\sigma^2 V(\mu)} \frac{\partial \mu}{\partial \beta_r} \frac{\partial \mu}{\partial \beta_s},$
para $r, s = 1, \dots, p$.

¹Biometrika **61**, 439-447.

Demostración:

(i) es directo desde la definición de Ψ , mientras que (ii) sigue de notar

$$\frac{\partial \Psi}{\partial \beta_j} = \frac{\partial \Psi}{\partial \mu} \frac{\partial \mu}{\partial \beta_j}.$$

Para mostrar (iii), note que

$$\mathbb{E}\{\Psi^2(\mu)\} = \frac{1}{\sigma^4} \mathbb{E}\left\{\frac{(Y - \mu)^2}{V^2(\mu)}\right\} = \frac{1}{\sigma^4} \frac{\sigma^2 V(\mu)}{V^2(\mu)} = \frac{1}{\sigma^2 V(\mu)}.$$

Por otro lado,

$$\begin{aligned} -\mathbb{E}\left(\frac{\partial \Psi}{\partial \mu}\right) &= -\mathbb{E}\left\{\frac{\partial}{\partial \mu}\left(\frac{Y - \mu}{\sigma^2 V(\mu)}\right)\right\} = -\frac{1}{\sigma^2} \mathbb{E}\left\{(Y - \mu) \frac{\partial}{\partial \mu} \frac{1}{V(\mu)} - \frac{1}{V(\mu)}\right\} \\ &= \frac{1}{\sigma^2 V(\mu)} \end{aligned}$$



Para probar (iv), considere

$$\begin{aligned} E\left(\frac{\partial \Psi}{\partial \beta_r} \frac{\partial \Psi}{\partial \beta_s}\right) &= E\left\{\left(\frac{\partial \Psi}{\partial \mu}\right) \frac{\partial \mu}{\partial \beta_r} \left(\frac{\partial \Psi}{\partial \mu}\right) \frac{\partial \mu}{\partial \beta_s}\right\} = E\left\{\left(\frac{Y - \mu}{V(\mu)}\right)^2 \frac{\partial \mu}{\partial \beta_r} \frac{\partial \mu}{\partial \beta_s}\right\} \\ &= \frac{1}{\sigma^4 V(\mu)} E\{(Y - \mu)^2\} \frac{\partial \mu}{\partial \beta_r} \frac{\partial \mu}{\partial \beta_s} = \frac{1}{\sigma^2 V(\mu)} \frac{\partial \mu}{\partial \beta_r} \frac{\partial \mu}{\partial \beta_s}, \end{aligned}$$

pues $\text{var}(Y) = \sigma^2 V(\mu)$. Mientras que

$$\begin{aligned} -E\left(\frac{\partial^2 \Psi}{\partial \beta_r \partial \beta_s}\right) &= -E\left\{\frac{\partial}{\partial \beta_r} \left(\frac{Y - \mu}{\sigma^2 V(\mu)}\right) \frac{\partial \mu}{\partial \beta_s}\right\} \\ &= -E\left\{\left[\frac{Y - \mu}{\sigma^2} \frac{\partial}{\partial \beta_r} \frac{1}{V(\mu)} - \frac{1}{\sigma^2 V(\mu)} \frac{\partial \mu}{\partial \beta_r}\right] \frac{\partial \mu}{\partial \beta_s}\right\} \\ &= \frac{1}{\sigma^2 V(\mu)} \frac{\partial \mu}{\partial \beta_r} \frac{\partial \mu}{\partial \beta_s}. \end{aligned}$$

Resultado 2:

Si la distribución de Y es especificada en términos de μ , y suponga que tenemos una log-verosimilitud asociada

$$-E\left(\frac{\partial^2 \Psi}{\partial \mu^2}\right) \leq -E\left(\frac{\partial^2 \ell}{\partial \mu^2}\right)$$

Demostración:

En el Resultado 1, basta notar que

$$\text{var}(Y) \geq -\frac{1}{E(\partial^2 \ell / \partial \mu^2)}.$$

Observación:

Evidentemente, conocer sólo la relación entre la media y varianza ofrece menos información que la obtenida desde la densidad de Y .



Ejemplo (modelo normal):

Suponga $V(\mu) = 1$, así la función de quasi-verosimilitud es dada por

$$Q(\mu; y) = \int_y^\mu \frac{y-t}{\sigma^2} dt = -\frac{1}{\sigma^2} \frac{(y-\mu)^2}{2}, \quad \mu, y \in \mathbb{R}.$$

Ejemplo (modelo Poisson):

Considere $V(\mu) = \mu$, luego

$$\begin{aligned} Q(\mu; y) &= \int_y^\mu \frac{y-t}{\sigma^2 t} dt = \frac{1}{\sigma^2} (y \log \mu - \mu - y \log y + y) \\ &\propto \frac{1}{\sigma^2} (y \log \mu - \mu). \end{aligned}$$

Si suponemos $\sigma^2 = 1$ sigue que $Q(\mu; y)$ es proporcional a la log-verosimilitud de $\text{Poi}(\mu)$.



Ejemplo (modelo Bernoulli):

En este caso, $V(\mu) = \mu(1 - \mu)$ y

$$\begin{aligned} Q(\mu; y) &= \int_y^\mu \frac{y - t}{\sigma^2 t(1 - t)} dt = \frac{1}{\sigma^2} \left\{ y \log \left(\frac{\mu}{1 - \mu} \right) + \log(1 - \mu) - \log y \right\} \\ &\propto \frac{1}{\sigma^2} \left\{ y \log \left(\frac{\mu}{1 - \mu} \right) + \log(1 - \mu) \right\} \end{aligned}$$

Ejemplo:

Considere la función de varianza $V(\mu) = \mu^2(1 - \mu)^2$

$$Q(\mu; y) = \int_y^\mu \frac{y - t}{\sigma^2 t^2(1 - t)^2} dt \propto \frac{1}{\sigma^2} \left\{ (2y - 1) \log \left(\frac{\mu}{1 - \mu} \right) - \frac{y}{\mu} - \frac{1 - y}{1 - \mu} \right\}.$$

Este tipo de función se recomienda para $0 < \mu < 1$ y $0 \leq y \leq 1$. Se debe notar que la función $Q(\mu; y)$ no corresponde a ninguna verosimilitud conocida.



Suponga Y_1, \dots, Y_n variables aleatorias independientes con quasi-verosimilitud conjunta:

$$Q(\boldsymbol{\mu}; \mathbf{y}) = \sum_{i=1}^n Q(\mu_i; y_i),$$

con $g(\mu_i) = \eta_i$ y $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$, para $i = 1, \dots, n$.

Por analogía, la función quasi-desvío es dada por

$$\begin{aligned} D(\mathbf{y}; \hat{\boldsymbol{\mu}}) &= 2\sigma^2 \{Q(\mathbf{y}; \mathbf{y}) - Q(\hat{\boldsymbol{\mu}}; \mathbf{y})\} = -2\sigma^2 Q(\hat{\boldsymbol{\mu}}; \mathbf{y}) \\ &= -2\sigma^2 \sum_{i=1}^n Q(\hat{\mu}_i; y_i) = 2 \sum_{i=1}^n \int_{\hat{\mu}_i}^{y_i} \frac{y_i - t}{V(t)} dt \end{aligned}$$



Las ecuaciones de quasi-verosimilitud, para estimar β se obtienen diferenciando $Q(\mu; \mathbf{y})$ y pueden ser escritas como $\Psi(\hat{\beta}) = \mathbf{0}$, con

$$\Psi(\beta) = \frac{1}{\sigma^2} \mathbf{D}^\top \mathbf{V}^{-1} (\mathbf{Y} - \mu),$$

donde

$$\mathbf{D} = \partial \mu / \partial \beta^\top = \mathbf{W}^{1/2} \mathbf{V}^{1/2} \mathbf{X},$$

con $\mathbf{V} = \text{diag}(V_1, \dots, V_n)$, $\mathbf{W} = \text{diag}(\omega_1, \dots, \omega_n)$ y $\omega_i = (d\mu_i / d\eta_i)^2 / V_i$.

Además,

$$\mathbf{K}(\beta) = -\mathbb{E} \left\{ \frac{\partial \Psi(\beta)}{\partial \beta^\top} \right\} = \frac{1}{\sigma^2} \mathbf{D}^\top \mathbf{V}^{-1} \mathbf{D}.$$

Esta matriz sigue el mismo rol que la matriz de información de Fisher. En efecto, la matriz de covarianza asintótica de $\hat{\beta}$ es

$$\text{Cov}(\hat{\beta}) \approx \mathbf{K}^{-1}(\hat{\beta}) = \sigma^2 (\mathbf{D}^\top \mathbf{V}^{-1} \mathbf{D})^{-1}.$$



El método 'Fisher'-scoring lleva al proceso iterativo

$$\begin{aligned}\beta^{(r+1)} &= \beta^{(r)} + (D^{(r)\top} V^{-(r)} D^{(r)})^{-1} D^{(r)} V^{-(r)} (Y - \mu^{(r)}) \\ &= (D^{(r)\top} V^{-(r)} D^{(r)})^{-1} D^{(r)\top} V^{-(r)} Z_*^{(r)},\end{aligned}$$

con $Z_* = D\beta + Y - \mu$.

Tenemos $D = W^{1/2} V^{1/2} X$, de este modo

$$\begin{aligned}D^\top V^{-1} D &= X^\top V^{1/2} W^{1/2} V^{-1} W^{1/2} V^{1/2} X = X^\top W X \\ D^\top V^{-1} &= X^\top W^{1/2} V^{-1/2} = X^\top W W^{-1/2} V^{-1/2}.\end{aligned}$$

De ahí que

$$\beta^{(r+1)} = (X^\top W^{(r)} X)^{-1} X^\top W^{(r)} Z^{(r)},$$

con $Z = \eta + W^{-1/2} V^{-1/2} (Y - \mu)$.

El estimador de momentos de σ^2 es dado por

$$\hat{\sigma}_{\text{MM}}^2 = \frac{1}{n-p} \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)}$$



Nelder y Pregibon (1987)² propusieron la función de quasi-verosimilitud extendida

$$Q^+(\mu; y) = -\frac{1}{2\sigma^2} D(y; \mu) - \frac{1}{2} \log\{2\pi\sigma^2 V(y)\},$$

donde

$$D(y; \mu) = 2 \int_{\mu}^y \frac{y-t}{V(t)} dt.$$

De este modo los estimadores de β y σ^2 son obtenidos mediante maximizar $Q^+(\mu; y)$.

El estimador de quasi-verosimilitud extendida $\hat{\beta}$, coincide con el estimador basado en $Q(\mu; y)$. Mientras que el estimador para σ^2 es dado por

$$\hat{\sigma}_{\text{EQL}}^2 = \left\{ \frac{D(y; \hat{\mu})}{n} \right\}^{-1}.$$

²Biometrika **74**, 221-232.

Considere $\mathbf{Y}_1, \dots, \mathbf{Y}_n$ vectores aleatorios independientes, con $\mathbf{Y}_i = (Y_{i1}, \dots, Y_{in_i})^\top$ y suponga

$$f(y; \theta_{ij}, \phi) = \exp[\phi\{y\theta_{ij} - b(\theta_{ij})\} + c(y; \phi)],$$

donde $E(Y_{ij}) = \mu_{ij} = b'(\theta_{ij})$, $\text{var}(Y_{ij}) = \phi^{-1}V_{ij}$, $V_{ij} = d\mu_{ij}/d\theta_{ij}$. Además,

$$g(\mu_{ij}) = \eta_{ij}, \quad \eta_{ij} = \mathbf{x}_{ij}^\top \boldsymbol{\beta}.$$

De este modo,

$$\boldsymbol{\Psi}(\boldsymbol{\beta}) = \phi \sum_{i=1}^n \mathbf{D}_i^\top \mathbf{V}_i^{-1} (\mathbf{Y}_i - \boldsymbol{\mu}_i), \quad \mathbf{K}(\boldsymbol{\beta}) = \phi \sum_{i=1}^n \mathbf{D}_i^\top \mathbf{V}_i^{-1} \mathbf{D}_i,$$

donde $\mathbf{D}_i = \mathbf{W}_i^{1/2} \mathbf{V}_i^{1/2} \mathbf{X}_i$.

