

# MAT-466: Funciones de inferencia

**Felipe Osorio**

`fosorios.mat.utfsm.cl`

Departamento de Matemática, UTFSM



## Configuración:

Vamos a suponer que el vector aleatorio  $\mathbf{Y}$  puede ser escrito como

$$\mathbf{Y} = (\mathbf{Y}_1^\top, \dots, \mathbf{Y}_n^\top)^\top,$$

donde los  $\mathbf{Y}_i$ 's son independientes. Asumiremos también que  $\mathbf{Y}$  sigue un modelo estadístico

$$\mathcal{P} = \{P_\beta : \beta \in \mathcal{B}\}, \quad \mathcal{B} \in \mathbb{R}^k,$$

y  $\mathcal{Y}$  es el espacio muestral.

## Definición 1:

Una función  $\Psi_n : \mathcal{B} \times \mathcal{Y} \rightarrow \mathbb{R}^k$  tal que  $\Psi_n(\beta; \cdot)$  es medible para todo  $\beta \in \mathcal{B}$  se dice una **función de estimación**.



## Observación:

Para una función de inferencia  $\Psi_n$  y una muestra  $\mathbf{Y} \in \mathcal{Y}$  dadas, es posible obtener un estimador  $\hat{\beta} = \hat{\beta}(\mathbf{Y})$  como [solución de la ecuación](#)

$$\Psi_n(\beta; \mathbf{Y}) = \mathbf{0}.$$

## Ejemplo (Regresión lineal):

Sea  $Y_1, \dots, Y_n$  variables independientes tal que  $Y_i \sim N(\mathbf{x}_i^\top \beta, \sigma^2)$  donde  $\mathbf{x}_i$  es vector de covariables asociada al  $i$ -ésimo individuo y  $\beta$  coeficientes de regresión. El estimador de mínimos cuadrados es

$$\Psi_n(\beta; \mathbf{Y}) = \sum_{i=1}^n \mathbf{x}_i (Y_i - \mathbf{x}_i^\top \beta).$$



## *Ejemplo (Regresión no-lineal):*

Considere  $Y_1, \dots, Y_n$  independientes con  $Y_i \sim N(f(\mathbf{x}_i; \boldsymbol{\beta}), \sigma^2)$  donde  $f(\cdot; \boldsymbol{\beta})$  es una función suave de  $\boldsymbol{\beta}$ . La función de estimación es dada por

$$\boldsymbol{\Psi}_n(\boldsymbol{\beta}; \mathbf{Y}) = \sum_{i=1}^n \left( \frac{\partial f(\mathbf{x}_i; \boldsymbol{\beta})}{\partial \boldsymbol{\beta}} \right) (Y_i - f(\mathbf{x}_i; \boldsymbol{\beta})).$$

La función  $\boldsymbol{\Psi}_n(\boldsymbol{\beta}; \mathbf{Y})$  es fácil de estudiar debido a que es lineal en los **residuos**

$$r_i(\boldsymbol{\beta}) = Y_i - f(\mathbf{x}_i; \boldsymbol{\beta}), \quad i = 1, \dots, n.$$



## Definición 2 (Vector de residuos):

Un vector aleatorio  $m$ -dimensional  $\mathbf{r}(\boldsymbol{\beta}; \mathbf{Y})$  es llamado un **vector de residuos** si:

(i)  $\mathbf{r}$  es **insesgado**, es decir,

$$E_{\boldsymbol{\beta}}\{\mathbf{r}(\boldsymbol{\beta}; \mathbf{Y})\} = \mathbf{0}.$$

(ii)  $\mathbf{r}$  tiene **matriz de variabilidad**

$$\mathbf{V}_r(\boldsymbol{\beta}) = \text{Cov}(\mathbf{r}(\boldsymbol{\beta}; \mathbf{Y}))$$

### Observación:

- ▶ Un vector  $\mathbf{r}(\boldsymbol{\beta})$  se dice **no-singular** si  $\mathbf{V}_r(\boldsymbol{\beta})$  es definida positiva para todo  $\boldsymbol{\beta}$ .
- ▶ Note el énfasis que se hace sobre **supuestos de momentos**.



Un vector  $\mathbf{r}(\beta)$  es llamado **suave** si  $\mathbf{r}(\cdot; \mathbf{Y})$  es diferenciable para casi todo  $\mathbf{Y}$ , y la **matriz de sensibilidad**  $m \times k$

$$\mathbf{S}_r(\beta) = \mathbb{E}_\beta \left\{ \frac{\partial \mathbf{r}(\beta)}{\partial \beta} \right\},$$

existe para todo  $\beta$ .

## Definición 3 (Información de Godambe):

Para un vector residual no-singular y suave,  $\mathbf{r}(\beta)$  se define la **matriz de información de Godambe**<sup>1</sup> como:

$$\mathbf{G}_r(\beta) = \mathbf{S}_r^\top(\beta) \mathbf{V}_r^{-1}(\beta) \mathbf{S}_r(\beta).$$

---

<sup>1</sup>Note la forma de **sandwich**



Sea  $\mathbf{A}(\boldsymbol{\beta})$  matriz  $p \times m$  no estocástica y considere

$$\mathbf{q}(\boldsymbol{\beta}) = \mathbf{A}(\boldsymbol{\beta})\mathbf{r}(\boldsymbol{\beta}).$$

De ahí que

$$\mathbf{V}_q(\boldsymbol{\beta}) = \text{Cov}(\mathbf{q}(\boldsymbol{\beta})) = \mathbf{A}(\boldsymbol{\beta})\mathbf{V}_r(\boldsymbol{\beta})\mathbf{A}^\top(\boldsymbol{\beta}).$$

### Resultado 1:

Para  $\mathbf{A}(\boldsymbol{\beta})$  matriz  $p \times m$  no estocástica y  $\mathbf{r}(\boldsymbol{\beta})$  regular. Entonces

$$\mathbf{S}_q(\boldsymbol{\beta}) = \mathbf{A}(\boldsymbol{\beta})\mathbf{S}_r(\boldsymbol{\beta}).$$

### Demostración:

En efecto,

$$\begin{aligned}\mathbf{S}_q(\boldsymbol{\beta}) &= \mathbf{E}\{\nabla_{\boldsymbol{\beta}}\mathbf{q}(\boldsymbol{\beta})\} = \mathbf{E}\{[\nabla_{\boldsymbol{\beta}}\mathbf{A}(\boldsymbol{\beta})]\mathbf{r}(\boldsymbol{\beta}) + \mathbf{A}(\boldsymbol{\beta})\nabla_{\boldsymbol{\beta}}\mathbf{r}(\boldsymbol{\beta})\} \\ &= [\nabla_{\boldsymbol{\beta}}\mathbf{A}(\boldsymbol{\beta})]\mathbf{E}\{\mathbf{r}(\boldsymbol{\beta})\} + \mathbf{A}(\boldsymbol{\beta})\mathbf{E}\{\nabla_{\boldsymbol{\beta}}\mathbf{r}(\boldsymbol{\beta})\} \\ &= \mathbf{A}(\boldsymbol{\beta})\mathbf{S}_r(\boldsymbol{\beta})\end{aligned}$$



Considere  $\mathbf{r}(\boldsymbol{\beta})$  y  $\mathbf{s}(\boldsymbol{\beta})$  vectores residuales  $m$ -dimensionales. Entonces,

$$\mathbf{S}_{r+s}(\boldsymbol{\beta}) = \mathbf{S}_r(\boldsymbol{\beta}) + \mathbf{S}_s(\boldsymbol{\beta}).$$

La linealidad de  $\mathbf{S}(\boldsymbol{\beta})$  es evidentemente, pues

$$\nabla_{\boldsymbol{\beta}}[\mathbf{r}(\boldsymbol{\beta}) + \mathbf{s}(\boldsymbol{\beta})] = \nabla_{\boldsymbol{\beta}}\mathbf{r}(\boldsymbol{\beta}) + \nabla_{\boldsymbol{\beta}}\mathbf{s}(\boldsymbol{\beta}).$$

Si además  $\mathbf{r}(\boldsymbol{\beta})$  y  $\mathbf{s}(\boldsymbol{\beta})$  son independientes. Entonces,

$$\mathbf{V}_{r+s}(\boldsymbol{\beta}) = \mathbf{V}_r(\boldsymbol{\beta}) + \mathbf{V}_s(\boldsymbol{\beta}).$$





Considere una re-parametrización  $\beta = \beta(\gamma)$ , donde  $\gamma$  es un vector  $l$ -dimensional ( $l \leq k$ ), y sea

$$q(\gamma) = r(\beta(\gamma))$$

Entonces,

$$V_q(\gamma) = V_r(\beta(\gamma)), \quad S_q(\gamma) = S_r(\beta(\gamma)) \nabla_\gamma \beta(\gamma).$$

En efecto

$$\begin{aligned} S_q(\gamma) &= E_\gamma \{ \nabla_\gamma q(\gamma) \} = E_\gamma \{ \nabla_\gamma r(\beta(\gamma)) \} = E_\gamma \{ \nabla_\beta r(\beta(\gamma)) \nabla_\gamma \beta(\gamma) \} \\ &= E_\gamma \{ \nabla_\beta r(\beta) \} \nabla_\gamma \beta(\gamma) = S_r(\beta(\gamma)) \nabla_\gamma \beta(\gamma) \end{aligned}$$

Adicionalmente, si  $r$  es no-singular, entonces

$$\begin{aligned} G_q(\gamma) &= S_q^\top(\gamma) V_q^{-1}(\gamma) S_q(\gamma) \\ &= \nabla_\gamma^\top \beta(\gamma) S_r^\top(\gamma) V_r^{-1}(\gamma) S_r(\beta(\gamma)) \nabla_\gamma \beta(\gamma) \\ &= \nabla_\gamma^\top \beta(\gamma) G_r(\beta(\gamma)) \nabla_\gamma \beta(\gamma) \end{aligned}$$



## Definición 4:

Un vector residual suave  $m$ -dimensional  $\mathbf{r}(\beta)$  es dicho **regular**, si  $k \leq m$  y la matriz de sensibilidad  $\mathbf{S}_r(\beta)$  tiene rango  $k$  para todo  $\beta$ .

## Resultado 2:

Un vector residual regular  $\mathbf{r}(\beta)$  es no-singular.

### *Demostración:*

(Por contradicción) Suponga que  $\mathbf{r}(\beta)$  es singular, en cuyo caso  $\mathbf{V}_r(\beta) = \text{Cov}(\mathbf{r}(\beta))$  no es definida positiva. Entonces, existe un vector no nulo  $\mathbf{c}$  tal que la combinación  $\mathbf{c}^\top \mathbf{r}(\beta)$  es cero casi seguramente. De ahí que

$$\mathbf{0} = \mathbf{S}_{\mathbf{c}^\top \mathbf{r}}(\beta) = \mathbf{c}^\top \mathbf{S}_r(\beta),$$

y de ahí que  $\mathbf{S}_r(\beta)$  es singular, lo que contradice que  $\mathbf{r}(\beta)$  sea regular. De ahí que  $\mathbf{V}_r(\beta)$  debe ser definida positiva.



Para un vector residual regular  $\mathbf{r}(\beta)$ , la matriz de información de Godambe

$$\mathbf{G}_r(\beta) = \mathbf{S}_r^\top(\beta) \mathbf{V}_r^{-1}(\beta) \mathbf{S}_r(\beta),$$

es definida positiva.

Para función de estimación regular  $\Psi_n : \mathbb{R}^k \rightarrow \mathbb{R}^k$ , la matriz de sensibilidad será cuadrada aunque no necesariamente simétrica.

Suponga  $\Phi_n(\beta) = \mathbf{A}(\beta) \Psi_n(\beta)$  con  $\mathbf{A}(\beta)$  matriz no singular  $k \times k$ . Entonces

$$\mathbf{G}_\Phi(\beta) = \mathbf{S}_\Psi^\top(\beta) \mathbf{A}(\beta) \{ \mathbf{A}^{-\top}(\beta) \mathbf{V}_\Psi^{-1}(\beta) \mathbf{A}^{-1}(\beta) \} \mathbf{A}(\beta) \mathbf{S}_\Psi(\beta)$$

$$\mathbf{S}_\Psi^\top(\beta) \mathbf{V}_\Psi^{-1}(\beta) \mathbf{S}_\Psi(\beta) = \mathbf{G}_\Psi(\beta),$$

de ahí que  $\Phi$  y  $\Psi$  son equivalentes.



## Definición 5 (Algoritmo Newton-scoring):

Considere la expansión en series de Taylor de  $\Psi(\beta)$  en torno de  $\beta_0$ , tenemos

$$\Psi(\beta) \approx \Psi(\beta_0) + \left. \frac{\partial \Psi(\beta)}{\partial \beta^\top} \right|_{\beta=\beta_0} (\beta - \beta_0),$$

como  $\Psi(\hat{\beta}) = 0$  y substituyendo  $\dot{\Psi}(\beta_0)$  por  $S_\Psi(\beta_0)$ , sigue que

$$\hat{\beta} = \beta_0 - S_\Psi^{-1}(\beta_0) \Psi(\beta_0), \quad (1)$$

esto sugiere considerar:

$$\beta^{(t+1)} = \beta^{(t)} - S_\Psi^{-1}(\beta^{(t)}) \Psi(\beta^{(t)}),$$

para llevar a cabo la estimación de parámetros.

### Observación:

Este procedimiento fue propuesto por Jørgensen y Knudsen (2004)<sup>2</sup> quienes lo denominaron **algoritmo Newton-scoring**.

---

<sup>2</sup>Scandinavian Journal of Statistics **31**, 93-114.



## Ejemplo:

Considere la función de estimación de mínimos cuadrados no lineales

$$\Psi_n(\beta) = \sum_{i=1}^n \mathbf{f}_i(\beta)(Y_i - f(\mathbf{x}_i; \beta)),$$

con  $\mathbf{f}_i(\beta) = \partial f(\mathbf{x}_i; \beta) / \partial \beta$ . En efecto,  $E\{\Psi_n(\beta)\} = \mathbf{0}$ , y

$$\begin{aligned} V(\beta) &= \sum_{i=1}^n \mathbf{f}_i(\beta) \text{var}(Y_i - f(\mathbf{x}_i; \beta)) \mathbf{f}_i^\top(\beta) = \sigma^2 \sum_{i=1}^n \mathbf{f}_i(\beta) \mathbf{f}_i^\top(\beta) \\ &= \sigma^2 \mathbf{F}^\top \mathbf{F}, \end{aligned}$$

donde  $\mathbf{F} = (\mathbf{f}_1, \dots, \mathbf{f}_n)^\top$ . Mientras que

$$S(\beta) = - \sum_{i=1}^n \mathbf{f}_i(\beta) \mathbf{f}_i^\top(\beta).$$

De este modo,

$$G(\beta) = \sigma^2 \mathbf{F}^\top \mathbf{F}.$$



## Definición 6:

Sea  $\mathbf{r}(\beta)$  vector de residuos no singular. Defina la **función quasi-score** como:

$$\mathbf{q}(\beta) = -\mathbf{S}_r^\top(\beta) \mathbf{V}_r^{-1}(\beta) \mathbf{r}(\beta),$$

donde  $\mathbf{S}_r$  y  $\mathbf{V}_r$  son las matrices de sensibilidad y variabilidad de  $\mathbf{r}(\beta)$ .

La matriz  $k \times m$ ,

$$\mathbf{A}(\beta) = -\mathbf{S}_r^\top(\beta) \mathbf{V}_r^{-1}(\beta),$$

es llamada **matriz de pesos de Crowder** (1987).<sup>3</sup> Además, las matrices de sensibilidad y variabilidad de  $\mathbf{q}(\beta)$  son

$$\begin{aligned}\mathbf{S}_q &= -\mathbf{S}_r^\top \mathbf{V}_r^{-1} \mathbf{S}_r = -\mathbf{G}_r \\ \mathbf{V}_q &= \mathbf{S}_r^\top \mathbf{V}_r^{-1} \mathbf{V}_r \mathbf{V}_r^{-1} \mathbf{S}_r = \mathbf{G}_r.\end{aligned}$$

Es decir,  $\mathbf{V}_q = -\mathbf{S}_q$ , y de ahí que

$$\mathbf{G}_q = \mathbf{G}_r.$$

---

<sup>3</sup>Biometrika 74, 591-597.



## *Observación:*

Cualquier función de estimación regular  $\Psi(\beta)$  satisfaciendo

$$-S_{\Psi}(\beta) = V_{\Psi}(\beta),$$

es una función quasi-score.

En particular, la **función score**

$$U(\beta) = \frac{\partial}{\partial \beta} \log p(\beta),$$

es una función quasi-score.



Suponga  $\mathbf{Y}_1, \dots, \mathbf{Y}_n$  vectores aleatorios independientes y sea

$$\mathbf{r}_i(\boldsymbol{\mu}_i), \quad \boldsymbol{\mu}_i = \boldsymbol{\mu}_i(\boldsymbol{\beta}),$$

vectores  $m_i$ -dimensionales. Considere la siguiente definición.

### Definición 7:

Una **función de estimación lineal** es definida como:

$$\mathbf{g}(\boldsymbol{\beta}) = \sum_{i=1}^n \mathbf{W}_i(\boldsymbol{\beta}) \mathbf{r}_i(\boldsymbol{\mu}_i),$$

donde  $\mathbf{W}_i = \mathbf{W}_i(\boldsymbol{\beta})$  es una matriz no aleatoria  $k \times m_i$ .





### *Ejemplo (mínimos cuadrados):*

En este caso tenemos

$$\mathbf{g}(\boldsymbol{\beta}) = \sum_{i=1}^n \mathbf{x}_i (Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}).$$

### *Ejemplo (M-estimación):*

Considere  $Y_i$  con distribución simétrica, la función de estimación  $M$  es

$$\mathbf{g}(\boldsymbol{\beta}) = \sum_{i=1}^n \mathbf{x}_i \psi(Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}),$$

donde  $\psi$  es una función impar.



## *Ejemplo (GLM):*

Suponga que

$$\mathbf{g}(\boldsymbol{\beta}) = \phi \sum_{i=1}^n \left( \frac{\omega_i}{V_i} \right)^{1/2} \mathbf{x}_i (Y_i - \mu_i),$$

donde  $E(Y_i) = \mu_i$ , con  $h(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$ .

## *Ejemplo (GEE):*

Considere

$$\mathbf{g}(\boldsymbol{\beta}) = \sum_{i=1}^n \mathbf{D}_i^\top \mathbf{C}_i^{-1} (\mathbf{Y}_i - \boldsymbol{\mu}_i),$$

donde  $\mathbf{Y}_i$  es un vector aleatorio con media  $\boldsymbol{\mu}_i$ ,  $\mathbf{D}_i = \nabla_{\boldsymbol{\beta}} \boldsymbol{\mu}_i$  es la matriz de modelo local y  $\mathbf{C}_i$  es la matriz de covarianza de trabajo.



## Previo (Ordenamiento de Löwner):

Si  $A$  y  $B$  son matrices de covarianza de la misma dimensión. Entonces  $A \geq B$  si y sólo si  $A - B$  es semidefinida positiva.<sup>4</sup>

## Definición 8:

Basado en la Ecuación (1) podemos definir una **función de estimación normalizada** como:

$$\bar{g}(\beta) = -S_g^{-1}(\beta)g(\beta).$$

---

<sup>4</sup>Esto corresponde a un ordenamiento parcial en el espacio de matrices semidefinidas positivas.

