

MAT-466: Propiedades de funciones de inferencia

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Resultado 1:

Sea \bar{g}_1 y \bar{g}_2 dos funciones de estimación normalizadas con matrices de información de Godambe K_1 y K_2 , respectivamente. La condición

$$\text{Cov}(\bar{g}_1, \bar{g}_2) = K_1, \quad (1)$$

implica las siguientes tres condiciones:

- (a) \bar{g}_1 y $\bar{g}_2 - \bar{g}_1$ son no correlacionadas.
- (b) $K_2 \geq K_1$.
- (c) $\text{var}(c^\top \bar{g}_2) \geq \text{var}(c^\top \bar{g}_1)$ para cualquier vector $c \in \mathbb{R}^k$.



Demostración:

Note que podemos escribir

$$\bar{\mathbf{g}}_2 = \bar{\mathbf{g}}_1 + (\bar{\mathbf{g}}_2 - \bar{\mathbf{g}}_1). \quad (2)$$

Si $\text{Cov}(\bar{\mathbf{g}}_1, \bar{\mathbf{g}}_2) = \mathbf{K}_1$ entonces

$$\begin{aligned} \text{Cov}(\bar{\mathbf{g}}_1, \bar{\mathbf{g}}_2 - \bar{\mathbf{g}}_1) &= \text{Cov}(\bar{\mathbf{g}}_1, \bar{\mathbf{g}}_2) - \text{Cov}(\bar{\mathbf{g}}_1, \bar{\mathbf{g}}_1) \\ &= \text{Cov}(\bar{\mathbf{g}}_1, \bar{\mathbf{g}}_2) - \mathbf{K}_1 = \mathbf{0}, \end{aligned}$$

lo que prueba (a). Tomando covarianzas en ambos lados de (2) lleva a

$$\mathbf{K}_2 = \mathbf{K}_1 + \mathbf{A}, \quad \mathbf{A} = \text{Cov}(\bar{\mathbf{g}}_2 - \bar{\mathbf{g}}_1),$$

como \mathbf{A} es semidefinida positiva, sigue (b). Además, tenemos que para cualquier \mathbf{c} ,

$$\begin{aligned} 0 &\leq \mathbf{c}^\top \mathbf{A} \mathbf{c} = \mathbf{c}^\top (\mathbf{K}_2 - \mathbf{K}_1) \mathbf{c} = \mathbf{c}^\top \mathbf{K}_2 \mathbf{c} - \mathbf{c}^\top \mathbf{K}_1 \mathbf{c} \\ &= \text{var}(\mathbf{c}^\top \bar{\mathbf{g}}_2) - \text{var}(\mathbf{c}^\top \bar{\mathbf{g}}_1), \end{aligned}$$

lo que implica (c).



Considere la función de inferencia

$$q(\beta) = - \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} r_i(\mu_i), \quad D_i = \partial \mu_i / \partial \beta^\top.$$

Note que

$$S_q = - \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} S_{r_i} = - \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} S_i D_i,$$

y

$$\begin{aligned} V_q &= \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} V_i V_i^{-1} S_i D_i = \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} S_i D_i \\ &= -S_q. \end{aligned}$$

De este modo, $q(\beta)$ es una función quasi-score con información de Godambe

$$G_q(\beta) = -S_q = V_q.$$



Por otro lado, suponga que

$$g(\beta) = \sum_{i=1}^n \mathbf{W}_i(\beta) \mathbf{r}_i(\mu_i).$$

De este modo,

$$\mathbf{S}_g = \sum_{i=1}^n \mathbf{W}_i \mathbf{S}_{r_i} = \sum_{i=1}^n \mathbf{W}_i \mathbf{S}_i \mathbf{D}_i,$$

mientras que

$$\mathbf{V}_g = \sum_{i=1}^n \text{Cov}(\mathbf{W}_i(\beta) \mathbf{r}_i(\mu_i)) = \sum_{i=1}^n \mathbf{W}_i \mathbf{V}_i \mathbf{W}_i^{\top}.$$

Es decir,

$$\mathbf{G}_g(\beta) = \mathbf{S}_g^{\top}(\beta) \mathbf{V}_g^{-1}(\beta) \mathbf{S}_g(\beta).$$



Resultado 2 (Optimalidad de Crowder):

Suponga $q(\beta)$ función quasi-score

$$q(\beta) = - \sum_{i=1}^n D_i^\top S_i^\top V_i^{-1} r_i(\mu_i)$$

Entonces $q(\beta)$ es **óptima para todas las funciones de estimación lineales** en el sentido que

$$G_g^{-1}(\beta) \geq G_q^{-1}(\beta),$$

para cualquier función de estimación lineal $g(\beta)$, con la igualdad si y sólo si

$$\bar{g}(\beta) = \bar{q}(\beta),$$

esto es, si $g(\beta)$ y $q(\beta)$ son equivalentes.



Demostración:

Deseamos mostrar la Ecuación (1) del Resultado 1. En efecto

$$\begin{aligned}\text{Cov}(\mathbf{q}, \mathbf{g}) &= \mathbb{E}(\mathbf{q}\mathbf{g}^\top) = -\mathbb{E}\left[\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{V}_i^{-1} \mathbf{r}_i \left(\sum_{j=1}^n \mathbf{W}_j \mathbf{r}_j\right)\right] \\ &= -\mathbb{E}\left[\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{V}_i^{-1} \mathbf{r}_i \sum_{j=1}^n \mathbf{r}_j^\top \mathbf{W}_j^\top\right] \\ &= -\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{V}_i^{-1} \sum_{j=1}^n \mathbb{E}(\mathbf{r}_i \mathbf{r}_j^\top) \mathbf{W}_j^\top,\end{aligned}$$

como \mathbf{r}_i y \mathbf{r}_j son no correlacionados para $i \neq j$, sigue que

$$\begin{aligned}\mathbb{E}(\mathbf{q}\mathbf{g}^\top) &= -\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{V}_i^{-1} \mathbb{E}(\mathbf{r}_i \mathbf{r}_i^\top) \mathbf{W}_i^\top = -\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{V}_i^{-1} \mathbf{V}_i \mathbf{W}_i^\top \\ &= -\sum_{i=1}^n \mathbf{D}_i^\top \mathbf{S}_i^\top \mathbf{W}_i^\top = -\mathbf{S}_g^\top\end{aligned}$$



Esto permite calcular

$$\begin{aligned}\text{Cov}(\bar{\mathbf{q}}, \bar{\mathbf{g}}) &= \text{E}\{\mathbf{S}_q^{-1} \mathbf{q} (\mathbf{S}_g^{-1} \mathbf{g})^\top\} = \mathbf{S}_q^{-1} \text{E}(\mathbf{q} \mathbf{g}^\top) \mathbf{S}_g^{-\top} \\ &= -\mathbf{S}_q^{-1} \mathbf{S}_g^\top \mathbf{S}_g^{-\top} = -\mathbf{S}_q^{-1} = \mathbf{G}_q^{-1},\end{aligned}$$

y esto implica la optimalidad de \mathbf{q} , lo que concluye la prueba.



Asuma una función de estimación lineal

$$\mathbf{g}_n(\boldsymbol{\beta}) = \sum_{i=1}^n \mathbf{W}_i \mathbf{r}_i(\boldsymbol{\mu}_i),$$

donde la notación enfatiza la dependencia de n . Asimismo $\mathbf{S}_n(\boldsymbol{\beta})$ y $\mathbf{V}_n(\boldsymbol{\beta})$ denotan las matrices de sensibilidad y variabilidad de \mathbf{g}_n .

Además, suponga que

$$\lim_{n \rightarrow \infty} \frac{1}{n} \mathbf{S}_n(\boldsymbol{\beta}) = \mathbf{S}(\boldsymbol{\beta}), \quad \lim_{n \rightarrow \infty} \frac{1}{n} \mathbf{V}_n(\boldsymbol{\beta}) = \mathbf{V}(\boldsymbol{\beta}).$$

Resultado 3:

Si $\mathbf{S}(\boldsymbol{\beta})$ es no singular, entonces $\mathbf{V}(\boldsymbol{\beta})$ es no singular.



Demostración:

La prueba se lleva a cabo por contradicción. Suponga que $V(\beta)$ es singular. Entonces existe un vector c tal que

$$c^\top V(\beta) c = 0,$$

y de ahí que

$$\lim_{n \rightarrow \infty} \frac{1}{n} c^\top V_n(\beta) c = 0,$$

lo cual implica que

$$\frac{1}{n} c^\top g_n(\beta) \xrightarrow{p} 0.$$

Asumiendo la continuidad del operador de sensibilidad $S(\cdot)$, tenemos

$$\begin{aligned} 0 &= S \left[\lim_{n \rightarrow \infty} \frac{1}{n} c^\top g_n(\beta) \right] = \lim_{n \rightarrow \infty} S \left[\frac{1}{n} c^\top g_n(\beta) \right] \\ &= c^\top \lim_{n \rightarrow \infty} \frac{1}{n} S_n(\beta) = c^\top S(\beta) \end{aligned}$$

lo que es una contradicción pues $S(\beta)$ ha sido asumida no singular.



Note que

$$\begin{aligned}\frac{1}{n}\mathbf{G}_n(\boldsymbol{\beta}) &= \frac{1}{n}\mathbf{S}_n^\top(\boldsymbol{\beta})\left[\frac{1}{n}\mathbf{V}_n(\boldsymbol{\beta})\right]^{-1}\frac{1}{n}\mathbf{S}_n(\boldsymbol{\beta}) \\ &\rightarrow \mathbf{S}^\top(\boldsymbol{\beta})\mathbf{V}^{-1}(\boldsymbol{\beta})\mathbf{S}(\boldsymbol{\beta}) = \mathbf{G}(\boldsymbol{\beta}),\end{aligned}$$

es decir, la información de Godambe promedio converge a un límite finito.

Asuma también que (Yuan y Jennrich, 1998)¹

$$\frac{1}{\sqrt{n}}\mathbf{g}_n(\boldsymbol{\beta}) \xrightarrow{D} \mathbf{N}_k(\mathbf{0}, \mathbf{V}(\boldsymbol{\beta})).$$

Usando que

$$\begin{aligned}\sqrt{n}(\hat{\boldsymbol{\beta}}_n - \boldsymbol{\beta}) &\stackrel{a}{=} \sqrt{n}\bar{\mathbf{g}}_n(\boldsymbol{\beta}) = -\left[\frac{1}{n}\mathbf{S}_n(\boldsymbol{\beta})\right]^{-1}\frac{1}{\sqrt{n}}\mathbf{g}_n(\boldsymbol{\beta}) \\ &\xrightarrow{D} \mathbf{N}_k(\mathbf{0}, \mathbf{S}^{-1}(\boldsymbol{\beta})\mathbf{V}(\boldsymbol{\beta})\mathbf{S}^{-\top}(\boldsymbol{\beta})),\end{aligned}$$

es decir

$$\sqrt{n}(\hat{\boldsymbol{\beta}}_n - \boldsymbol{\beta}) \xrightarrow{D} \mathbf{N}_k(\mathbf{0}, \mathbf{G}^{-1}(\boldsymbol{\beta})).$$

¹Journal of Multivariate Analysis 65, 245-260.

Problema:

Se desea probar hipótesis de la forma:

$$H_0 : \beta = \beta_0, \quad \text{versus} \quad H_1 : \beta \neq \beta_0,$$

donde β_0 es un valor fijado.

Consideraremos los siguientes estadísticos de prueba:

- ▶ Test de Wald.
- ▶ Test tipo-score (de multiplicadores de Lagrange).

Observación:

- ▶ En el contexto de funciones de inferencia este tipo de test han sido discutidos por Rotnitzky y Jewell (1990)² y Boos (1992)³
- ▶ Mientras que Crudu y Osorio (2020)⁴ abordan el **test gradiente** (de forma bilineal) en **extremum estimation**.

²Biometrika 77, 485-497.

³The American Statistician 46, 327-333.

⁴Economic Letters 187, 108885



Test de hipótesis en funciones de inferencia

Basado en la normalidad asintótica del estimador $\hat{\beta}_n$, sigue que

$$\mathbf{Z}_n = \sqrt{n}\mathbf{G}^{1/2}(\beta_0)(\hat{\beta}_n - \beta_0) \xrightarrow{D} \mathbf{N}_k(\mathbf{0}, \mathbf{I}).$$

de ahí que

$$\begin{aligned} W_n &= \mathbf{Z}_n^\top \mathbf{Z}_n = n(\hat{\beta}_n - \beta_0)^\top \mathbf{G}(\beta_0)(\hat{\beta}_n - \beta_0) \\ &\xrightarrow{D} \chi^2(k). \end{aligned}$$

Lo que lleva al **test de tipo-Wald** para probar $H_0 : \beta = \beta_0$, que es definido por la región crítica

$$\{W_n \geq \chi_{a-\alpha}^2(k)\}$$

que bajo H_0 es asintóticamente de tamaño α .



Test de hipótesis en funciones de inferencia

Por otro lado, usando la condición

$$\frac{1}{\sqrt{n}} \mathbf{g}_n(\boldsymbol{\beta}_0) \xrightarrow{D} N_k(\mathbf{0}, \mathbf{V}(\boldsymbol{\beta}_0)),$$

así

$$\mathbf{V}^{-1/2}(\boldsymbol{\beta}_0) \frac{1}{\sqrt{n}} \mathbf{g}_n(\boldsymbol{\beta}_0) \xrightarrow{D} N_k(\mathbf{0}, \mathbf{I}),$$

lo que permite definir el **estadístico tipo-score** para probar hipótesis de la forma $H_0 : \boldsymbol{\beta} = \boldsymbol{\beta}_0$, como:

$$R_n = \frac{1}{n} \mathbf{g}_n^\top(\boldsymbol{\beta}) \mathbf{V}^{-1}(\boldsymbol{\beta}_0) \mathbf{g}_n(\boldsymbol{\beta}_0) \xrightarrow{D} \chi^2(k).$$



Observación:

- ▶ Lamentablemente no es simple extender los estadísticos tipo-Wald y tipo-score para manipular **hipótesis más generales**, por ejemplo:

$$H_0^1 : \boldsymbol{\theta}_1 = \boldsymbol{\theta}_{10}, \quad H_0^2 : \mathbf{h}(\boldsymbol{\theta}) = \mathbf{0}, \quad H_0^3 : \boldsymbol{\beta} = \mathbf{h}(\boldsymbol{\lambda}),$$

que son conocidos como **hipótesis sobre sub-vectores** y **hipótesis no lineales** en forma implícita y explícita, respectivamente.

- ▶ Algún esfuerzo se está llevando a cabo en extender el **test gradiente** (o **de forma bilineal**) a este contexto más general (ver, por ejemplo, Crudu y Osorio, 2020).

